

基于自适应权重的多源部分域适应^{*}

田青^{1,2,3}, 孙灿宇¹, 储奕¹

¹(南京信息工程大学 软件学院, 江苏 南京 210044)

²(数字取证教育部工程研究中心 (南京信息工程大学), 江苏 南京 210044)

³(计算机软件新技术国家重点实验室 (南京大学), 江苏 南京 210023)

通讯作者: 田青, E-mail: tianqing@nuist.edu.cn



摘要: 作为机器学习的一个新兴领域, 多源部分域适应问题由于其源域自身的复杂性、领域之间的差异性以及目标域自身的无监督性, 给相关研究带来了挑战, 以致目前鲜有相关工作被提出. 在该场景下, 多个源域中的无关类样本在域适应过程中会造成较大的累积误差和负迁移. 此外, 现有多源域适应方法大多未考虑不同源域对目标域任务的贡献度不同. 因此, 本文提出基于自适应权重的多源部分域适应方法(AW-MSPDA). 首先, 我们构建了多样性特征提取器以有效利用源域的先验知识. 同时我们设计了多层次分布对齐策略从不同层面消除了分布差异, 促进了正迁移. 此外, 为量化不同源域贡献度以及过滤源域无关类样本, 我们利用相似性度量以及伪标签加权方式构建自适应权重. 最后, 通过大量实验验证了所提出 AW-MSPDA 算法的泛化性以及优越性.

关键词: 多源部分域适应; 负迁移; 多样性特征提取; 多层次分布对齐; 自适应权重

中图法分类号: TP311

中文引用格式: 田青, 孙灿宇, 储奕. 基于自适应权重的多源部分域适应. 软件学报. <http://www.jos.org.cn/1000-9825/7015.htm>

英文引用格式: Tian Q, Sun CY, Chu Y. Adaptive weight-induced multi-source partial domain adaptation. Ruan Jian Xue Bao/Journal of Software (in Chinese). <http://www.jos.org.cn/1000-9825/7015.htm>

Adaptive Weight-induced Multi-Source Partial Domain Adaptation

TIAN Qing^{1,2,3}, SUN Can-Yu¹, CHU Yi¹

¹(School of Software, Nanjing University of Information Science and Technology, Nanjing 210044, China)

²(Engineering Research Center of Digital Forensics, Ministry of Education (Nanjing University of Information Science and Technology), Nanjing 210044, China)

³(State Key Laboratory for Novel Software Technology (Nanjing University), Nanjing 210023, China)

Abstract: As an emerging field of machine learning, multi-source partial domain adaptation (MSPDA) poses challenges to related research due to the complexities of the involved source domains, the diversities between the domains, and the unsupervised nature of the target domain itself, leading to rarely few works presented. In this scenario, the irrelevant class samples in multiple-source domains will cause large cumulative errors and negative transfer during domain adaptation. In addition, most of the existing multi-source domain adaptation methods do not consider the different contributions of different source domains to the target domain tasks. Therefore, this paper proposes an Adaptive Weight-induced Multi-Source Partial Domain Adaptation (AW-MSPDA). Firstly, we construct a diverse feature extractor to effectively utilize the prior knowledge of the source domain. Meanwhile, multi-level distribution alignment strategy is constructed to eliminate distribution discrepancies from different levels to promote positive transfer. Moreover, the pseudo-label weighting and similarity measurement are used to construct adaptive weights to quantify the contribution of different source domains and filter samples which are irrelevant to the source domain. Finally, the generalization and performance superiority of the proposed AW-MSPDA algorithm are evaluated by extensive experiments.

* 基金项目: 国家自然科学基金 (62176128); 计算机软件新技术国家重点实验室开放课题(KFKT2022B06); 中央高校基本科研业务费 (NJ2022028); 江苏省“青蓝工程”优秀青年骨干教师人才计划; 江苏省研究生科研实践创新计划 (KYCX22_1205)

收稿时间: 2023-05-15; 修改时间: 2023-07-07; 采用时间: 2023-08-24; jos 在线出版时间: 2023-09-11

Key words: multi-source partial domain adaptation; negative transfer; diverse feature extraction; multi-level distribution alignment; adaptive weight

在信息爆发式增长和人力成本高昂的背景下,作为机器学习的一个新兴范式,域适应(domain adaptation)通过借助已有的数据标注知识辅助可更好地解决无标注的目标域任务,近年受到了渐多的研究和关注^[1-3].现有域适应研究大多都侧重于从单个标记源域到未标记目标域的相关知识迁移,从而完成单源域适应的目的.然而在现实应用中,为获得更好的目标域预测性能,通常赋予源域更丰富的信息,但随着目标域复杂度和领域之间差异的不断增加,现有域适应方法的有效性受到一定的限制.为更好地应对上述问题,多源域适应(Multi-Source Domain Adaptation, MSDA)作为一种新的域适应场景被提出^[4-6],相较于单源域适应场景,多个源域能够为目标域提供更为多样化的适应信息,并获得更优的目标域适应性能.

然而,随着领域知识的快速增长,导致源域所含的信息愈发复杂,其中的无关信息难免会给域适应带来干扰,即来自不同源域的不同信息对目标域而言无相关性,尤其当源域和目标域仅存在部分共享特性时,这 will 导致域适应的负迁移问题,进而影响域适应的性能.分析总结上述问题可见,传统多源域适应方法的问题设置和前提假设存在一定局限性,即源域和目标域共享同一个标记空间不能较好地贴合实际问题,且基于此假设的域适应方法并不能较好地解决上述问题.为应对以上问题和挑战,多源部分域适应随后被提出^[7].在多源部分域适应场景中,目标域与源域共享部分特性,且每个源域具有自己的特有特征,该场景与上述问题场景贴合.然而,多源部分域适应问题由于其源域信息的复杂性、领域之间的差异性以及目标域自身的无监督性,给相关研究带来了挑战,目前未有其他的多源部分域适应工作被提出.针对多源部分域适应问题,为更直观地对其特性展开相关分析,该问题的表现形式如图1所示,其中左侧为不同源域的样本分布情况,右侧为目标域样本的分布情况,不同形状代表不同类别的样本.如图所示,源域之间共享部分类别且每个源域都有自己特有的类别,但目标域类别是所有源域类别并集的一个子集.

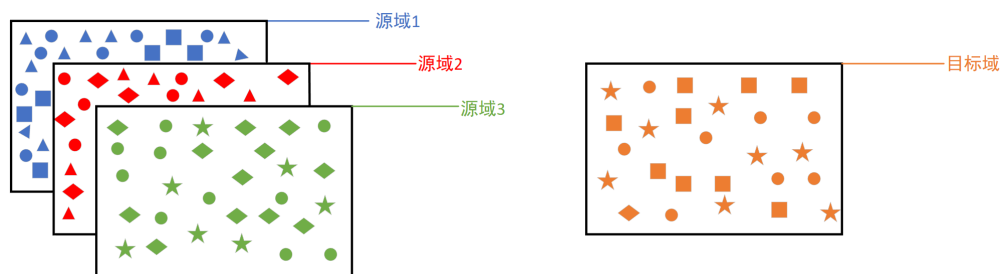


图1 多源部分域适应问题示意图

基于以上研究现状和分析,我们针对多源部分域适应问题展开相关研究.在多源部分域适应问题中,不同源域之间存在一定的分布差异,在域适应过程中若忽略不同源域间的域漂移^[8-9],将给域适应过程带来累积误差,甚至导致较严重的负迁移问题,从而影响模型整体性能.此外,在多源部分域适应场景中,由于不同源域的差异,在域适应过程中其对目标域决策任务的贡献度也将不同.可见,若简单地将所有源域合并并不能有效地解决多源域适应问题,更重要地,在该场景中对目标域而言,不同的源域中均存在无关类样本,在域适应过程中若不对其加以妥善分离或处理,同样会给域适应过程造成累积性的负迁移影响,并对整体模型预测精度造成危害.尽管多源部分域适应相关研究稀少,但已有若干多源域适应方法被提出,并且它们大多通过训练利用多个源域内的样本并平均其对目标域样本标签的预测结果,而并没有区别考虑不同源域对目标域任务的贡献度差异.尽管有个别工作采取了加权的建模策略,但其并没有对来自不同源域的无关类样本进行排除性加权处理,这仍将给域适应过程造成负迁移影响,进而降低模型的整体适应效果.

结合上述分析,依据源域与目标域共享部分特征以及不同源域具有各自私有特征的特点,我们通过构建域不变特征提取器和域私有特征提取器,在实现从多个源域到目标域适应的同时,保护不同领域自身的私有

特性. 具体而言, 通过最大化不同源域间私有特征的差异来学习源域多样性的知识. 为从多层面刻画并减小领域间的差异, 我们分别提出域级别对齐和类级别对齐以实现更紧密的领域对齐. 在上述基础上, 考虑到多源域适应场景的特点, 我们以分布差异为相似性度量方式, 通过构建域级别的自适应权重来量化不同源域对目标域分类任务的贡献度, 以实现目标域分类任务精度的提升. 此外, 鉴于多源部分域适应场景中类标记空间的特殊性, 我们利用模型预测的目标伪标签构建类级别的自适应权重, 并对决策分类器进行加权, 以实现源域无关类样本的自动过滤, 排除其对域适应过程的负迁移影响. 基于以上考虑, 本文提出了一种基于自适应权重的多源部分域适应算法(Adaptive Weight-induced Multi-Source Partial Domain Adaptation, AW-MSPDA). 总结而言, 我们的主要贡献如下:

- (1) 针对多源部分域适应场景, 从多个角度构建了基于自适应权重的多源部分域适应算法(AW-MSPDA). 该方法通过联合分布对齐和自适应权重策略有效地实现了多源部分域适应任务, 为多源部分域适应研究提供了新的范例和参考.
- (2) 结合 AW-MSPDA 的问题场景, 为挖掘所有源域和目标域的域内和域间关系, 构建了多样性特征表示抽取架构, 通过提取域不变特征和域私有特征等混合特征来多层面迁移源域丰富知识, 以更好地解决多源部分域适应问题.
- (3) 为促进 AW-MSPDA 的正迁移成分, 通过构建多层次分布对齐策略, 同时从域级别和类级别实现源域与目标域之间的对齐, 有效减少域漂移所带来的负面影响; 从缩小类内距和扩大类间距的角度, 减少分类边界样本对域适应过程带来的负面影响.
- (4) 通过分布差异度量, 构建自适应更新的源域样本权重, 以自适应方式量化 AW-MSPDA 中不同源域对目标域的贡献度. 此外, 还利用目标域所获伪标签设计自适应的类级别权重, 以过滤筛除源域中的无关类样本, 消除其对 AW-MSPDA 性能的负面影响.

1 相关工作

1.1 多源域适应方法

多源域适应是域适应的一类场景, 其有效结合实际并缓解了单源域适应中单源域样本来源单一和多样性不足的问题, 但这也给该类问题研究带来更多的挑战. 目前, 多源域适应问题已有不少相关研究被提出. 例如, 工作^[10-11]通过理论分析, 针对 MSDA 任务设计了多种趋势策略, 如通过构建对抗学习网络获取域不变表征. 为获得优越的目标预测器, Li 等人^[12]通过同时提取源域内部以及源域和目标域之间的关系实现不同域分布的对齐. Zhao 等人^[13]提供了相应的泛化边界, 使得其所提模型可以在分类和回归设置下同时提取域不变特征和任务鉴别特征. Peng 等人^[5]所提方法中的矩匹配是一种在新创建的多域数据集上测试的方法, 其在使用对抗学习训练时使源域之间相互对齐, 并将源域与目标域进行对齐.

在多源域适应场景中, 由于不同源域对目标域任务具有不同的贡献, 因此结合源域预测器对目标域样本进行标签的预测是完成目标域任务的关键. 其中最为常见且直接的方法是对所有源域分类器对于目标域样本预测的性能进行平均, 但该方法未考虑不同源域与目标域数据分布的差异. Zhu 等人^[14]提出多特征空间自适应网络来对齐领域特定分布和域特定分类器, 以减少在分类边界附近的样本所造成的错误分类. 然而, 不同的源域对于目标域分类通常提供不同的贡献, 因此在进行目标域标签预测时, 应该对不同源域采取不同权重的加权策略. 为了确定不同源域的组合权重, Zhang 等人^[15]提出了多源选择转移方法, 通过构建最近邻样本选择、加权选择和 Top- k 选择三种选择策略来选择与目标域更为相似的源域. Zhao 等人^[6]通过选择更接近目标样本的训练源样本和舍弃低相似性样本, 定义一种新的遵循标准高斯分布相似度的策略来学习源域样本权重. 与上述方法不同, Zhao 等人^[16]提出通过对抗学习策略来训练域适应模型, 其将所有域紧密结合在一起以实现域适应任务.

尽管多源域适应问题已有不少相关研究被提出, 但仍存在较大的改进和提升空间, 如应从不同的视角来实现不同源域之间以及源域与目标域之间的对齐, 即在域对齐的前提下再进行类级对齐会更好. 尤其对于多

源部分域适应问题, 由于源域标记空间和目标域标记空间的不匹配, 域间在存在较大边缘分布差异的同时, 其条件分布差异也是影响整体域适应性能的重要因素.

1.2 分布差异度量及最大平均差异方法

域适应是迁移学习的一种特殊类别, 其从源域数据中学习, 并向相关但不完全相同的目标域数据进行知识的迁移^[1-3], 即在有效地消除分布差异的同时, 将源域知识迁移到任务相似的目标域, 辅助后者更好地学习. 域适应通常通过减少领域之间的分布差异来实现, 其中分布差异主要包括边缘分布差异^[17-19]和条件分布差异^[20-22], 其表达式分别为:

$$P(X_s) \neq P(X_t), P(Y|X_s) \neq P(Y|X_t) \quad (1)$$

其中, P 代表概率分布, X_s 和 X_t 分别代表源域和目标域, Y 则代表各领域对应的标签.

显然, 为实现领域对齐, 找到合适的分布差异度量标准至关重要. 目前, 已有多种分布度量策略被提出, 并被广泛应用于衡量域适应问题中领域之间的差异, 如最大平均差异 MMD . 基于 MMD 的域适应通过最小化领域分布间分布均值距离, 拉近源域和目标域, 从而消除源域和目标域数据分布之间的边缘分布差异. MMD 基本的假设是: 如果对于所有输入为分布生成的样本空间的函数 f , 如果两个分布生成的足够多的样本在 f 上的对应均值相等, 则认为这两个分布是相同分布. 如果用 F 表示在样本空间上的连续函数集, 则 MMD 可表达如下:

$$\text{MMD}[F, p, q] = \sup_{f \in F} (E_{x \sim p}[f(x)] - E_{y \sim q}[f(y)]) \quad (2)$$

假设 X 和 Y 为分别从分布 p 和 q 中采样得到的两个数据集. 据此, 则源域表示 $D_s = \{(x_i^s, y_i^s)\}_{i=1}^{n_s}$ 和目标域表示 $D_t = \{(x_i^t)\}_{i=1}^{n_t}$ 为服从不同分布的两个数据集. 由此, MMD 可用下面的式子刻画:

$$\text{MMD}[F, D_s, D_t] = \sup_{f \in F} \left(\frac{1}{n_s} \sum f(x_s) - \frac{1}{n_t} \sum f(x_t) \right) \quad (3)$$

基于以上公式表达, Pan 等人^[23]采用 MMD 来实现边缘分布自适应, 有效地减少了源域和目标域之间的分布差异并实现了域适应. 受深度学习在计算机视觉等领域的成功应用启发, Tzeng 等人^[24]将 MMD 拓展到深度学习结构中, 进一步拓展了差异度量策略在域适应领域的应用效果. 此外, 在上述工作的基础上, Long 等人^[25]拓展了多核 MMD 并将其应用到域适应. 考虑到不同领域之间的多种分布差异, Yu 等人^[26]结合边缘分布差异和条件分布差异构建联合 MMD 实现不同领域之间的联合分布.

MMD 作为应用最为广且适用性较好的一种分布度量标准, 在域适应研究和应用中取得了不错的性能.

2 基于自适应权重的多源部分域适应

在本节中, 我们首先对问题场景进行定义, 然后详细说明所提出的 AW-MSPDA 的构成部分, 其包括多样性特征提取、多层次分布对齐以及自适应权重学习等模块. 此外, 考虑到不同源域对目标域分类任务的贡献不同, 提出针对目标域分类任务的加权标签预测方式. 然后, 根据所提模型的具体步骤总结出对应的算法流程. 所提 AW-MSPDA 算法的模型架构如图 2 所示, 其中 $S_1, S_2 \dots S_K$ 分别表示 K 个源域. G_c 和 G_p 表示两个不同的特征提取器, 其分别为域不变特征提取器和域私有特征提取器. G_y 和 G_d 分别为样本类别分类器和域分类器. 所提 AW-MSPDA 算法包括多层次的分布对齐, 其由域级别对齐和类级别对齐组成, 并且从特征的层面利用分布差异度量方式构建权重 w , 以衡量不同源域对目标域分类任务的贡献. 此外, 基于所构建的类别分类器 G_y 所获得的伪标签构建源域样本的自适应类别级权重, 过滤掉对目标域而言无关的源域样本. L_m 表示实现域级对齐和类级对齐的模型训练损失. L_y 和 L_d 分别表示源域分类训练损失以及域分类训练损失, 对上述损失项构成的总体目标损失最小优化可实现多源部分域适应.

2.1 符号定义与问题假设

在多源部分域适应问题中, 存在 K 个有标记的源域 $\{D_{s_k}\}_{k=1}^K$ 和 1 个未标记的目标域 $D_t = \{X_t\} = \{x_t^j\}_{j=1}^{n_t}$, 每个源域 $D_{s_k} = \{(X_{s_k}, Y_{s_k})\} = \{(x_{s_k}^i, y_{s_k}^i)\}_{i=1}^{n_{s_k}}$ 由 n_{s_k} 个样本组成, $y_{s_k}^i$ 为第 k 个源域中第 i 个样本的标签, 目标域由 n_t 个样本组成. 该场景中每个源域之间、源域和目标域之间都存在分布差异, 即 $P(X_{s_1}) \neq P(X_{s_2}) \neq \dots \neq P(X_{s_K}) \neq P(X_t)$. 此外, 每个源域的标记空间、源域和目标域的标记空间也不相同, 但目标域的标记空间是所有源域标记空间并集的一个子集, 即 $Y_{s_1} \neq Y_{s_2} \neq \dots \neq Y_{s_K} \neq Y_t, Y_t \subseteq \bigcup_{i=1}^K Y_{s_i}$.

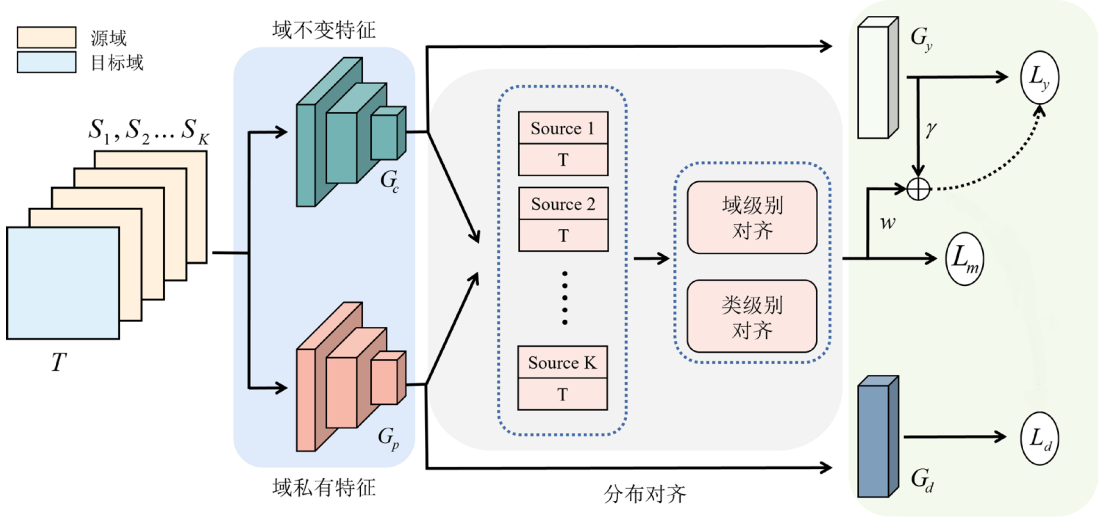


图2 基于自适应权重的多源部分域适应方法模型架构

2.2 多样性特征提取

在无监督多源域适应问题中, 单一源域的知识可能不足以覆盖目标任务的解决, 因此考虑利用具有更丰富可迁移知识的多个源域协同地解决目标域任务. 但不同源域具有不同的知识, 若忽略其相互之间的差异往往并不能取得较好的迁移效果, 并给域适应过程中带来阻碍性的负迁移影响. 为进一步对多个源域提取出具有多样性的特征, 我们构建域不变特征和域私有特征提取器, 对多个源域的特征进行提取. 首先, 我们利用预训练的深度卷积特征提取网络将源域样本和目标域样本的表征转换到共享特征空间中, 其具体形式如下所示:

$$\begin{cases} f_{s_k}^i = \phi(x_{s_k}^i, \theta_\phi), \\ f_t^j = \phi(x_t^j, \theta_\phi), \end{cases} \quad (4)$$

其中, f_{s_k} 和 f_t 分别表示映射到共享特征空间的源域和目标域特征. 此外, $i=1,2,\dots,n_{s_k}$, $j=1,2,\dots,n_t$, $k=1,2,\dots,K$, θ_ϕ 表示共享特征提取器 ϕ 的相关参数.

为了有效地消除不同域间的分布差异, 考虑到不同源域与目标域间虽存在一定的分布差异, 但源域与目标域在整体上存在一定的相似性, 即源域存在一定的潜在特征与目标域特征相似. 除此之外, 目标域样本特征并非仅由域不变特征构成, 由于多个源域的存在, 其包含了多样性的特征, 因此除域不变特征外, 不同源域所具有特征空间的联合可能覆盖了目标域特征的所有特性. 结合上述分析, 我们将源域和目标域所共享的特征空间的表征划分为域不变特征和域私有特征, 其分别表示在域适应过程中源域的可迁移知识以及源域特有的不可迁移知识, 以有效地实现多个源域到目标域的适应任务. 具体而言, 针对域不变特征, 将其表示如下:

$$\begin{cases} f_{c_{s_k}}^i = G_{c_k}(f_{s_k}^i, \theta_{c_k}), \\ f_{c_{t_k}}^j = G_{c_k}(f_{t_k}^j, \theta_{c_k}), \end{cases} \quad (5)$$

其中, $i=1,2,\dots,n_{s_k}$, $j=1,2,\dots,n_{t_k}$, $k=1,2,\dots,K$. G_{c_k} 表示第 k 个源域上由参数 θ_{c_k} 刻画的域不变特征提取器.

除上述域不变特征提取器外, 为保持源域特征的多样性, 我们还构建域私有特征提取器, 其形式如下:

$$\begin{cases} f_{p_{s_k}}^i = G_{p_k}(f_{s_k}^i, \theta_{p_k}), \\ f_{p_{t_k}}^j = G_{p_k}(f_{t_k}^j, \theta_{p_k}), \end{cases} \quad (6)$$

其中, $i=1,2,\dots,n_{s_k}$, $j=1,2,\dots,n_{t_k}$, $k=1,2,\dots,K$. G_{p_k} 表示第 k 个源域的域私有特征提取器, θ_{p_k} 为相应的网络参数.

基于构建的域不变特征提取器和域私有特征提取器, 通过不断训练迭代可提取出域不变特征以及域私有特征, 进而利用所提特征更好地实现领域对齐. 为保持域不变特征的判别性, 我们对每个源域构建分类器 G_{y_k} 并利用源域的监督信息对域不变特征进行训练. 对于第 k 个源域, 域不变特征的优化目标函数表示如下:

$$\min_{\theta_\phi, \theta_{c_k}, \theta_{y_k}} L_{y_k}(\theta_\phi, \theta_{c_k}, \theta_{y_k}) = \frac{1}{n_{s_k}} \sum_{s_k^j \in X_{s_k}} L_{ce}(G_{y_k}(G_{c_k}(\phi(x_{s_k}^j))), y_{s_k}^j) \quad (7)$$

此外, 为有效地提取域私有特征, 我们进一步构建域分类器 G_d , 对提取域私有特征后的不同源域样本进行域分类, 由此使得所提取域私有特征更具判别性, 为实现多源域的多样性特征提取打下基础. 对于第 k 个源域, 域私有特征的优化目标函数表示如下:

$$\min_{\theta_\phi, \theta_{p_k}, \theta_d} L_{d_k}(\theta_\phi, \theta_{p_k}, \theta_d) = \frac{1}{n_{s_k}} \sum_{s_k^j \in X_{s_k}} L_{ce}(G_d(G_{p_k}(\phi(x_{s_k}^j))), d_k) \quad (8)$$

其中, L_{ce} 表示交叉熵损失函数, d_k 表示第 k 个源域上样本所对应的域标签.

2.3 多层次分布对齐

2.3.1 域级别对齐

基于上述构建的特征提取器, 可获得源域样本和对应目标域样本的域不变特征和域私有特征表示. 具体地, 为获得域不变特征需要通过最小化不同域间的公共特征差异来实现, 包括不同源域之间以及源域和目标域之间的差异. 为更好地度量这些分布差异, 不失一般性, 我们采用 **MMD** 度量作为分布差异度量标准, 为此针对于不同源域间的分布差异, 构建如下形式的损失函数:

$$\begin{aligned} L_{ss} &= \frac{2}{K \cdot (K-1)} \sum_{k_1=1}^{K-1} \sum_{k_2=k_1+1}^K \text{MMD}(X_{s_{k_1}}, X_{s_{k_2}}) \\ &= \frac{2}{K \cdot (K-1)} \sum_{k_1=1}^{K-1} \sum_{k_2=k_1+1}^K \left\| \frac{1}{n_{s_{k_1}}} \sum_{i=1}^{n_{s_{k_1}}} \mathbf{K}(f_{c_{s_{k_1}}}^i) - \frac{1}{n_{s_{k_2}}} \sum_{j=1}^{n_{s_{k_2}}} \mathbf{K}(f_{c_{s_{k_2}}}^j) \right\|_{\mathbf{H}}^2 \end{aligned} \quad (9)$$

其中, $\|\cdot\|_{\mathbf{H}}$ 表示再生核希尔伯特空间范数, 而 \mathbf{K} 是核化特征变换. $n_{s_{k_1}}$ 和 $n_{s_{k_2}}$ 表示对应源域上的批处理样本数.

此外, 对不同源域和目标域之间的特征分布同样需要进行域对齐. 需要指出的是, 来自源域的特征多样性会在目标域上有不同程度的体现, 为此应对所提取出的域不变特征以及域私有特征同时进行源域和目标域之间的适应性对齐. 出于建模的统一考虑, 对提取的域不变特征和域私有特征进行组合表示, 为此定义

$F_{s_k} = [f_{c_{s_k}}; f_{p_{s_k}}]$ 表示第 k 个源域样本的特征融合, $F_{t_k} = [f_{c_{t_k}}; f_{p_{t_k}}]$ 表示基于第 k 个源域特征提取器所得的目标

域特征融合. 基于上述特征融合, 构建如下形式的源域与目标域之间的域级对齐损失函数:

$$\begin{aligned}
L_{st} &= \frac{1}{K \cdot K} \sum_{k_1=1}^K \sum_{k_2=1}^K \text{MMD}(X_{s_{k_1}}, X_{t_{k_2}}) \\
&= \frac{1}{K \cdot K} \sum_{k_1=1}^K \sum_{k_2=1}^K \left\| \frac{1}{n_{s_{k_1}}} \sum_{i=1}^{n_{s_{k_1}}} \mathbf{K}(F_{s_{k_1}}^i) - \frac{1}{n_{t_{k_2}}} \sum_{j=1}^{n_{t_{k_2}}} \mathbf{K}(F_{t_{k_2}}^j) \right\|_{\text{H}}^2
\end{aligned} \quad (10)$$

除了上述域级别的领域对齐外, 不同源域间的域私有特征也需要进行域级别的对齐, 但在进行域私有特征对齐时, 与前文所述域对齐有所不同. 具体而言, 为有效地学到不同源域中的多样性特征以覆盖目标域特征的所有特性, 需要最大程度地最大化不同源域私有特征的差异, 使得所提取的域不变特征与域私有特征具有更好的区分性和更低的相似性. 基于以上分析, 构建源域私有特征之间的对齐损失函数如下:

$$\begin{aligned}
L_{\text{diverse}} &= \frac{2}{K(K-1)} \sum_{k_1=1}^{K-1} \sum_{k_2=k_1+1}^K \text{MMD}(X_{s_{k_1}}, X_{s_{k_2}}) \\
&= \frac{2}{K(K-1)} \sum_{k_1=1}^{K-1} \sum_{k_2=k_1+1}^K \left\| \frac{1}{n_{s_{k_1}}} \sum_{i=1}^{n_{s_{k_1}}} \mathbf{K}(f_{p_{s_{k_1}}}^i) - \frac{1}{n_{s_{k_2}}} \sum_{j=1}^{n_{s_{k_2}}} \mathbf{K}(f_{p_{s_{k_2}}}^j) \right\|_{\text{H}}^2
\end{aligned} \quad (11)$$

综合以上特征对齐函数, 可得如下的域级综合对齐函数:

$$L_{\text{domain}} = L_{ss} + L_{st} - L_{\text{diverse}} \quad (12)$$

2.3.2 类级别对齐

除上述的域级跨域适应对齐之外, 为减少处于分类边界附近的样本给域适应带来的分布偏差, 我们针对不同域间的条件分布差异, 引入类级分布匹配. 需要注意的是, 相较于传统多源域适应问题, 我们所探究的多源部分域适应问题中的不同源域、源域和目标域标记空间存在较大差异, 且目标域的标记空间是所有源域标记空间并集的子集. 在此场景下, 若忽略源域中的无关类样本直接简单地对源域和目标域进行类级别对齐, 源域那些无关类将给域适应带来干扰和阻碍, 即带来负迁移的影响. 因此, 我们在实现类级别对齐时, 应避免直接对源域和目标域施加对齐操作. 实验结果表明, 处于分类边界附近的样本通常具有类别归属模糊的特性. 为应对以上问题, 我们提出最大化不同类之间的差异, 同时最小化同类的差异, 即通过采取扩大类间距和缩小类内距的思路实现类级别对齐. 综合上述分析, 我们提出通过减少不同源域数据之间的类内距、扩大相同源域的不同类的间距以及扩大目标域内不同类的间距来联合实现类级别的领域对齐, 其对应的损失函数构建如下:

$$\begin{aligned}
L_{\text{class}} &= \frac{2}{K \cdot (K-1)} \sum_{k_1=1}^{K-1} \sum_{k_2=k_1+1}^K \sum_{r=1}^{C_{k_1 k_2}} \text{MMD}(X_{s_{k_1}}^r, X_{s_{k_2}}^r) \\
&\quad - \left(\frac{1}{K} \sum_{k=1}^K \sum_{\eta=1}^{C_k-1} \sum_{\eta_2=\eta+1}^{C_k} \text{MMD}(X_{s_k}^{\eta_1}, X_{s_k}^{\eta_2}) + \frac{1}{K} \sum_{k=1}^K \sum_{\eta=1}^{C_t-1} \sum_{\eta_2=\eta+1}^{C_t} \text{MMD}(X_{t_k}^{\eta_1}, X_{t_k}^{\eta_2}) \right)
\end{aligned} \quad (13)$$

其中, $C_{k_1 k_2}$ 表示任意两个源域 $X_{s_{k_1}}$ 和 $X_{s_{k_2}}$ 之间的公共的类别数. C_k 表示第 k 个源域的类别数, C_t 为目标域的类别数. 值得注意的是, 尽管我们不能接触到目标域的真实标签, 但我们可以通过伪标签估计其类别数.

最后, 综合考虑以上域级别对齐和类级别对齐损失函数, 可得多层次跨域分布对齐的总体损失函数如下:

$$\min L_m = L_{\text{domain}} + \alpha L_{\text{class}} \quad (14)$$

其中, α 表示平衡系数, 用于平衡域级别损失和类别损失的规模.

2.4 自适应权重学习

在无监督多源域适应场景中, 因不同源域与目标域之间的相似度不同, 以致其对目标域迁移任务的贡献度也将不同. 因此, 对不同源域和目标域间相似度的有效度量是解决多源域适应问题的关键. 现有多源域适应研究大多采取平均贡献度的建模思想, 并未有效区分不同源域对目标域任务的贡献差异. 基于上述分析, 我们提出一种源域适应权重自适应更新的学习策略来计算不同源域的适应贡献度. 具体而言, 对不同源域和

目标域的分布差异进行度量, 来衡量不同源域与目标域之间的相似性, 并对所得的 K 个权重进行归一化处理, 由此可得第 k 个源域对目标域的自适应贡献权重 w_k 如下:

$$w_{\text{sim}}^k = \frac{1}{\text{Dis}(X_{s_k}, X_t)}$$

$$w_k = \frac{w_{\text{sim}}^k}{\sum_{k=1}^K w_{\text{sim}}^k} \quad (15)$$

其中, $\text{Dis}(X_{s_k}, X_t)$ 表示第 k 个源域和目标域在共享特征空间中的分布距离, 其定义如下:

$$\text{Dis}(X_{s_k}, X_t) = \left\| \frac{1}{n_{s_k}} \sum_{i=1}^{n_{s_k}} \mathbf{K}(f_{s_k}^i) - \frac{1}{n_t} \sum_{j=1}^{n_t} \mathbf{K}(f_t^j) \right\|_{\mathbf{H}}^2 \quad (16)$$

基于上述所得的源域自适应权重, 借助各个源域的标签类别分类器, 可得到如下的源域加权集成的目标域样本类别标签预测结果:

$$Y_t = \sum_{k=1}^K w_k \cdot G_{y_k}(F_{t_k}) \quad (17)$$

此外, 在多源部分域适应场景中, 除不同源域对目标域任务的适应贡献不同外, 源域中的不同类别对目标域任务的贡献也存在一定的差异. 结合其标记空间的特殊性, 为有效地对每个类别的贡献进行度量, 我们提出基于目标域样本的决策标签的类别输出结果来求算不同源域分类器的适应类别权重. 通过这种方式, 实现对源域无关类样本的自动过滤, 从而减轻源域中无关类样本在域适应过程中所造成的负迁移影响, 以获得较好的目标域分类精度. 具体而言, 我们对所有目标样本在分类器上的预测求均值, 以得到对应源域的类级别权重, 对于第 k 个源域的类级别的权重计算如下:

$$\gamma_k = \frac{1}{n_t} \sum_{i=1}^{n_t} y_{t_k}^i \quad (18)$$

结合域级别权重和类级别权重的特性, 在多源部分域适应场景下, 我们对公式(7)进行优化, 以区分不同源域对目标任务的贡献以及过滤源域无关类样本, 第 k 个源域上的域不变特征分类损失计算如下:

$$\min_{\theta_\phi, \theta_c, \theta_{y_k}} L_{y_k}(\theta_\phi, \theta_c, \theta_{y_k}) = \frac{1}{n_{s_k}} \sum_{x_{s_k}^i \in X_{s_k}} w_k \gamma_k^c L_{ce} \left(G_{y_k} \left(G_{c_k} \left(\phi(x_{s_k}^i) \right) \right), y_{s_k}^i \right) \quad (19)$$

其中, γ_k^c 表示第 k 个源域上类别 c 的自适应权重.

2.5 总体目标函数

针对多源部分域适应问题, 综合考虑以上多样性特征提取、多层次分布对齐和自适应权重学习等建模成分, 我们构建 AW-MSPDA 的总体优化目标函数如下:

$$\min_{\theta_\phi, \theta_c, \theta_p, \theta_y, \theta_d} L_{\text{total}} = L_m(\theta_\phi, \theta_c, \theta_p) + \sum_{k=1}^K L_{y_k}(\theta_\phi, \theta_c, \theta_{y_k}) + \beta \sum_{k=1}^K L_{d_k}(\theta_\phi, \theta_{p_k}, \theta_d) \quad (20)$$

其中, β 为损失项平衡因子. 为更直观地描述所提 AW-MSPDA 的完整优化过程, 其完整计算流程如算法 1 所示.

算法 1 AW-MSPDA 算法

输入: 标记源域样本 $D_{s_k} = \{(X_{s_k}, Y_{s_k})\}$, 无标记的目标域 $D_t = \{X_t\}$, 最大迭代次数 T , 预训练模型 $\phi(\cdot, \theta_\phi)$;

输出: 目标域预测标签 Y_t ;

- 1: 对域不变特征提取器 $G_{c_k}(\cdot, \theta_{c_k})_{k=1}^K$ 和域私有特征提取器 $G_{p_k}(\cdot, \theta_{p_k})_{k=1}^K$ 进行初始化, 对决策分类器 $\{G_{y_k}\}_{k=1}^K$ 和域分类器 G_d 初始化;
- 2: **repeat**
- 3: 根据公式(4)提取源域和目标域在共享特征空间的表征;
- 4: 根据公式(5)提取源域和目标域的域不变特征;
- 5: 根据公式(6)提取源域和目标域的域私有特征;
- 6: 通过公式(8)使得域私有特征更具判别性, 从而训练域分类器;
- 7: 根据公式(12)实现域级别对齐, 并计算更新损失 L_{domain} ;
- 8: 根据公式(13)实现类级别对齐, 并计算更新损失 L_{class} ;
- 9: 结合公式(12)和公式(13)构建并根据公式(14)计算更新多层次分布对齐损失 L_m ;
- 10: 结合公式(16)并利用公式(15)构建并计算域级别的自适应权重 w_k ;
- 11: 根据公式(18)构建并计算类级别的自适应权重 γ_k ;
- 12: 通过公式(19)来保持域不变特征的判别性, 并训练对应的决策分类器;
- 13: 根据公式(20)计算并更新总体目标损失 L_{total} ;
- 14: 根据公式(17)对目标域伪标签进行更新;
- 15: 更新相应模型参数;
- 16: **until** 最大迭代次数 T 及 L_{total} 收敛

3 实验与结果分析

我们在基准数据集上对多源部分域适应场景下的分类任务进行评估实验, 以此来全面评估所提 AW-MSPDA 算法的性能. 首先我们针对实验中的数据集进行相关介绍. 然后, 针对实验过程中的实验设置进行说明. 其次, 结合所提方法的特殊性, 我们分别对传统多源域适应问题以及多源部分域适应问题进行相关实验, 并与现有相关工作进行对比以及结果分析.

3.1 数据集介绍及设置

我们在广泛使用的 3 个域适应数据集上进行相关实验, 即 Digit-Five 数据集^[27]、Office-31 数据集^[28]和 Office-Home 数据集^[29]. 三个数据集的详细情况如下:

- (1) Digit-Five 包括了 5 个不同的数字分类数据集, 即 MNIST-M 数据集、MNIST 数据集、USPS 数据集、SVHN 数据集以及 Synthetic Digits 数据集. 每个数据集中包含 10 个类别的样本, 在多源域适应场景中, 源域和目标域共享标记空间, 而在多源部分域适应场景中, 多个源域之间、源域和目标域之间共享部分标记空间, 且目标域的标记空间是所有源域标记空间并集的一个子集, 在该场景中, 我们设置每个源域拥有 5 个类别的样本, 目标域拥有 7 个类别的样本.
- (2) Office-31 作为域适应领域中被广泛使用的数据集, 其各子数据集存在一定的相似性, 因此利用源域训练所得分类器在目标域直接进行分类并不会出现较大的误差, 但在多源部分域适应场景中若忽略各子数据集间的分布差异会在域适应过程中造成累积性误差, 从而显著影响模型分类精度. 该数据集包括 3 个子数据集, 且每个数据集中包含 31 个类别的样本. 在实验中, 针对多源部分域适应问题, 我们设置目标域包含 21 个类别的样本, 另外 2 个源域也拥有 21 个类别的样本, 尽管它们的类别数相同, 但标记空间是不同的.
- (3) Office-Home 同样作为被广泛使用的基准数据集, 其与 Office-31 数据集存在部分相似性, 但该数据

集包含更多类别的样本. 因此, 在多源域适应场景下, 该数据集对域适应任务更具挑战性. 该数据集包含 4 个不同的域, 每个域中包含 65 个类别的样本.

3.2 实验设置及对比方法

3.2.1 实验设置

在实验中, 采用 ResNet-50 作为预训练的特征提取器; 采用 Softmax 分类器作为初始化模型; 采用标准的随机梯度下降优化器对网络进行训练(初始学习速率设置为 $1e-3$, 在训练过程中呈指数衰减). 超参数 α 和 β 在 $[0-1]$ 区间搜索. 本文实验平台主要配置信息如下, 内存: 64GB, CPU: AMD 3800X, GPU: NVIDIA GeForce RTX 3090.

3.2.2 对比方法

由于本文所提方法应用场景的特殊性且直接相关的方法稀少, 因此我们分别在多源域适应场景下和多源部分域适应场景下对所提 AW-MSPDA 算法进行评估. 我们的对比方法包括单源域适应(UDA)方法、多源域适应(MSDA)方法、单源部分域适应(PDA)方法和多源部分域适应(MSPDA)方法. 其中 UDA 方法包括: DANN^[1]、DAN^[2]、ADDA^[3]、CORAL^[30]以及 MCD^[31], MSDA 方法包括: MDAN^[16]、DCTN^[4]、M³SDA^[5]、MDDA^[6]、MFSAN^[14]、LtC-MSDA^[32]以及 CASR^[33], PDA 方法包括: PADA^[34]、SAN^[35]以及 ETN^[36], MSPDA 方法包括 PFSA^[7].

3.3 实验结果及分析

3.3.1 多源域适应实验

在多源域适应场景中, 源域和目标域共享同一个标记空间. 而在部分域适应场景中, 在理想情况下通过源域无关类样本的筛选可将部分域适应问题转化为无监督域适应问题, 实现无关类样本的完全筛选. 结合多源域适应中具有大量的源域样本, 其所含源域知识较为丰富且多样, 从而同样可能存在部分知识并不能较好地迁移到目标域中的情况, 因此本文将所提 AW-MSPDA 算法直接应用到多源域适应场景中, 所提自适应权重学习策略不会对源域所包含的类别进行过滤, 且通过加权的方式可过滤处于分类边界的源域样本, 以避免该类样本在域适应过程中被错误分类从而引起模型整体的性能退化. 针对三个域适应数据集, 我们进行了如下多源域适应实验:

基于 Digit-Five 数据集: 结合上述分析, 在该数据集上进行的实验结果如表 1 所示, 其中用加粗的形式标记最优结果. 其中, “mm”表示 MNIST-M 数据集, “mt”表示 MNIST 数据集, “up”表示 USPS 数据集, “sv”表示 SVHN 数据集以及“sy”表示 Synthetic Digits 数据集. 在数据集的设置方面, Single-Best 表示在所有源域中单源域适应的最佳性能, Source-Combine 是指将所有源域组合为一个源域并实现单源域适应. 从结果中可以观察到, 所提 AW-MSPDA 算法相较于现有最新的多源域适应方法在部分任务上能够有较为优越的性能, 尤其是在“→sv”任务上有较大地提升. 此外, 即使在部分数据集上并不能取得更高的精度, 但所得精度与对比方法相差不大, 且在平均精度上我们所提 AW-MSPDA 方法取得了最优结果.

基于 Office-31 数据集: 我们针对该数据集进行了多源域适应场景问题的相关实验, 其实验结果如表 2 所示, 最优结果用加粗的形式体现. 其中 D 表示 DSLR 数据集, W 表示 Webcam 数据集以及 A 表示 Amazon 数据集. 通过对结果的观察可知, 与上述实验结果类似, 在部分任务中本文所提 AW-MSPDA 算法取得了最优结果, 尤其是在“→A”任务中精度提升幅度较高, 在没有取得更高精度的任务中也取得了次优结果, 且在平均精度上取得了最高的精度.

基于 Office-Home 数据集: 我们针对该数据集进行了多源域适应场景问题的相关实验, 其实验结果如表 3 所示, 最优结果用加粗的形式体现. 其中“→A”表示 Art 数据集作为目标域, “→C”表示 Clipart 数据集作为目标域, “→P”表示 Product 数据集作为目标域, “→R”表示 Real World 数据集作为目标域. 通过观察可知, 所提 AW-MSPDA 方法在更具挑战性的 Office-Home 数据集实验中, 相较于现有多源域适应方法也取得了较高的精度, 证明了所提方法的有效性和优越性.

表 1 多源域适应场景下 AW-MSPDA 在 Digit-Five 上的实验结果(%)

数据集设置	实验方法	→mm	→mt	→up	→sv	→sy	平均结果
Single-Best	DAN	63.8	96.3	94.2	62.5	85.4	80.4
	DANN	71.3	97.6	92.3	63.5	85.4	82.0
	ADDA	71.6	97.9	92.8	75.5	86.5	84.8
Source-Combine	DAN	67.9	97.5	93.5	67.8	86.9	82.7
	DANN	70.8	97.9	93.5	68.5	87.4	83.6
	ADDA	72.3	97.9	93.1	75.0	86.7	85.0
	MCD	72.5	96.2	95.3	78.9	87.5	86.1
Multi-Source	MDAN	69.5	98.0	92.4	69.2	87.4	83.3
	DCTN	70.5	96.2	92.8	77.6	86.8	84.8
	M ² SDA	72.8	98.4	96.1	81.3	89.6	87.7
	MDDA	78.6	98.8	93.9	79.3	89.7	88.1
	LtC-MSDA	85.6	99.0	98.3	83.2	93.0	91.8
	CASR	90.2	99.7	98.3	86.4	96.3	94.1
	AW-MSPDA(Ours)	90.7	99.3	98.1	88.2	94.8	94.2

表 2 多源域适应场景下 AW-MSPDA 在 Office-31 上的实验结果(%)

数据集设置	实验方法	→D	→W	→A	平均结果
Single-Best	DAN	99.0	96.0	54.0	83.0
	ADDA	99.4	95.3	54.6	83.1
Source-Combine	DAN	98.8	96.2	54.9	83.3
	ADDA	99.2	96.0	55.9	83.7
	MCD	99.5	96.2	54.4	83.4
Multi-Source	MDAN	99.2	95.4	55.2	83.3
	DCTN	99.6	96.9	54.9	83.8
	M ² SDA	99.4	96.2	55.4	83.7
	MDDA	99.6	97.1	56.2	84.2
	LtC-MSDA	99.6	97.2	56.9	84.6
	CASR	99.8	99.8	76.2	91.9
	AW-MSPDA(Ours)	99.7	98.9	78.3	92.3

表 3 多源域适应场景下 AW-MSPDA 在 Office-Home 上的实验结果(%)

数据集设置	实验方法	→A	→C	→P	→R	平均结果
Single-Best	DAN	68.2	56.5	80.3	75.9	70.2
	DANN	67.9	55.9	80.4	75.8	70.0
Source-Combine	DAN	68.5	59.4	79.0	82.5	72.4
	DANN	68.4	59.1	79.5	82.7	72.4
	CORAL	68.1	58.6	79.5	82.7	72.2
	MFSAN	72.1	62.0	80.3	81.8	74.1
Multi-Source	M ² SDA	64.1	62.8	76.2	78.6	70.4
	AW-MSPDA(Ours)	71.8	63.4	79.7	82.5	74.3

3.3.2 多源部分域适应实验

相较于多源域适应问题，多源部分域适应具有更高的域适应难度。具体而言，在该场景中目标域标记空间是所有源域标记空间并集的一个子集，若忽略源域中的无关类样本在域适应过程中所造成的负迁移，会对整体分类任务精度造成显著负面影响。因此，结合上述分析，我们将所提 AW-MSPDA 方法应用于不同的数据集中，进行了如下多源部分域适应场景下的实验：

基于 Digit-Five 数据集：在该数据集上进行的实验结果如表 4 所示，其中用加粗的形式标记最优结果。通过对实验结果观察可知，我们所提 AW-MSPDA 方法针对多源部分域适应问题的分类精度，相较于现有多源域适应方法和部分域适应方法有显著提高，相较于仅有的多源部分域适应方法也有一定的提升，在各任务中均取得了最优的结果。通过仔细研究仅有的 MSPDA 方法 PFSA，我们发现它并没有对源域施加自适应的权重以区分不同源域的贡献，从而导致性能低于我们的方法。综合以上分析，结合实验结果可以证明所提 AW-MSPDA 能够有效地解决多源部分域适应问题，且具备优越性和先进性。

表 4 多源部分域适应场景下 AW-MSPDA 在 Digit-Five 上的实验结果(%)

对比方法类型	实验方法	→mm	→mt	→up	→sv	→sy	平均结果
MSDA	MDAN	55.4	79.8	73.1	35.4	43.1	57.4
	M ³ SDA	69.3	98.0	96.3	47.8	78.3	77.9
	LtC-MSDA	60.0	97.6	97.7	43.5	83.7	76.5
PDA	PADA	63.9	90.4	93.1	40.5	62.8	70.1
	SAN	55.4	96.1	96.5	32.6	55.1	67.1
	ETN	48.7	93.6	93.4	36.6	64.6	67.4
MSPDA	PFSA	69.5	98.2	99.0	68.7	86.9	84.5
	AW-MSPDA(Ours)	72.4	98.4	99.2	70.6	89.3	86.0

表 5 多源部分域适应场景下 AW-MSPDA 在 Office-31 上的实验结果 (%)

对比方法类型	实验方法	→D	→W	→A	平均结果
MSDA	MDAN	74.2	71.9	28.6	58.2
	M ³ SDA	78.2	71.0	32.9	60.7
	LtC-MSDA	83.3	76.2	31.0	63.5
PDA	PADA	75.6	73.8	38.0	62.5
	SAN	83.1	77.8	39.8	66.9
	ETN	83.9	78.5	41.1	67.8
MSPDA	PFSA	84.2	79.0	40.2	67.8
	AW-MSPDA(Ours)	84.9	81.8	48.6	71.8

基于 Office-31 数据集: 在该数据集上进行的实验结果如表 5 所示, 其中用加粗的形式标记最优结果. 通过观察可知, 在该数据集实验中, 本文所提 AW-MSPDA 方法在所有任务中均取得最优结果, 且平均精度相较于现有方法存在优越性. 综合上述分析, 所提方法的有效性和先进性得到验证.




图 3 参数敏感性分析

3.4 参数敏感性分析

由公式(14)和公式(20)可知, 所提 AW-MSPDA 算法中包含 2 个超参数, 即多层次分布对齐部分类别对齐因子 α 和域分类损失超参数 β . 为了探索其对模型性能的影响, 我们在 Office-31 数据集上对参数敏感性进行了实验, 结果如图 3 所示, 通过观察可以发现模型的精度随着超参数的调整变化不大, 且当 α 和 β 同时取到 0.5 时, 模型可以取得最好的性能.

4 结论

本文解决一个更加实际且更具挑战性的任务—多源部分域适应, 并提出对应的学习框架(AW-MSPDA). 该场景下源域往往包含丰富的信息, 目标域特征可能由多个源域特征表出, 我们使用多样性特征提取方式来构

建模型,同时提出域级别的自适应权重来区分不同源域对目标域的贡献.为了有效实现源域知识的迁移,我们提出多层次的对齐方式来促进正迁移.此外,我们利用目标域伪标签设计类级别的自适应权重,来对分类器进行加权以过滤源域中的无关类样本.我们通过实验在多源域适应和多源部分域适应场景下证明了该方法的有效性.在未来,我们将探索更精确的过滤算法以排除源域中的无关类样本,从而实现更好的域适应性能.

References:

- [1] Ganin Y, Ustinova E, Ajakan H, Germain P, Larochelle H, Laviolette F, Marchand M, Lempitsky V. Domain-adversarial training of neural networks. *Machine Learning Research*, 2016,17(1):2096–2030.
- [2] Long MS, Cao Y, Wang JM, Jordan MI. Learning transferable features with deep adaptation networks. In: *Proc. of the 32nd Int'l Conf. on Machine Learning*. Lille: JMLR.org, 2015. 97–105.
- [3] Tzeng E, Hoffman J, Saenko K, Darrell T. Adversarial discriminative domain adaptation. In: *Proc. of the 2017 IEEE/CVF Conf. on Computer Vision and Pattern Recognition*. Hawaii: IEEE, 2017. 7167–7176.
- [4] Xu RJ, Chen ZL, Zuo WM, Yan JJ, Lin L. Deep cocktail network: Multi-source unsupervised domain adaptation with category shift. In: *Proc. of the 2018 IEEE/CVF Conf. on Computer Vision and Pattern Recognition*. Salt Lake City: IEEE, 2018. 3964–3973.
- [5] Peng XC, Bai QX, Xia X, Huang ZJ, Saenko K, Wang B. Moment matching for multi-source domain adaptation. In: *Proc. of the 17th Int'l Conf. on Computer Vision*, 2019,1406–1415.
- [6] Zhao SC, Wang GZ, Zhang SH, Gu Y, Li YX, Song ZC, Xu PF, Hu RB, Chai H, Keutzer K. Multi-source distilling domain adaptation. *Proc. of the 2020 AAAI Conf. on Artificial Intelligence*, 2020, 12975–12983.
- [7] Fu YY, Zhang M, Xu X, Cao Z, Ma C, Ji YL, Zuo K, Lu HM. Partial feature selection and alignment for multi-source domain adaptation. In: *Proc. of the 2021 IEEE/CVF Conf. on Computer Vision and Pattern Recognition*. On-line: IEEE, 2021. 16654–16663.
- [8] Ni J, Qiu Q, and Chellappa R. Subspace interpolation via dictionary learning for unsupervised domain adaptation. In: *Proc. of the 2013 IEEE/CVF Conf. on Computer Vision and Pattern Recognition*. Portland: IEEE, 2013. 692–699.
- [9] Yosinski J, Clune J, Bengio Y, Lipson H. How transferable are features in deep neural networks. *Advances in Neural Information Processing Systems*, 2014, 27: 3320–3328.
- [10] Blitzer J, Crammer K, Kulesza A, Pereira F, Wortman J. Learning bounds for domain adaptation. *Advances in Neural Information Processing Systems*, 2007, 20: 129–136.
- [11] Hoffman J, Mohri M, Zhang NS. Algorithms and theory for multiple-source adaptation. *Advances in Neural Information Processing Systems*, 2018, 31: 8256–8266.
- [12] Li YT, Murias M, Major S, Dawson G, Carlson DE. Extracting relationships by multi-domain matching. *Advances in Neural Information Processing Systems*, 2018, 31: 6799–6810.
- [13] Zhao H, Zhang SH, Wu GH, Costeira JP, Moura JMF, Gordon GJ. Adversarial multiple source domain adaptation. *Advances in Neural Information Processing System*, 2018, 31: 8568–8579.
- [14] Zhu Y, Zhuang F, Wang D. Aligning domain-specific distribution and classifier for cross-domain classification from multiple sources. *Proc. of the 2019 AAAI Conf. on Artificial Intelligence*, 2019, 5989–5996.
- [15] Zhang J, Zhou WE, Chen XQ, Yao W, Cao L. Multisource selective transfer framework in multiobjective optimization problems. *IEEE Trans. on Evolutionary Computation*, 2019,24(3):424–438.
- [16] Zhao SC, Li B, Xu PF, Yue XY, Ding GG, Keutzer K. Madan: multi-source adversarial domain aggregation network for domain adaptation. *International Journal of Computer Vision*, 2021,129(8):2399–2424.
- [17] Duan LX, Tsang IW, Xu D. Domain transfer multiple kernel learning. *IEEE Trans. on Pattern Analysis and Machine Intelligence*, 2012,34(3):465–479.
- [18] Gretton A, Borgwardt KM, Rasch MJ, Scholköpfung B, Smola A. A kernel two-sample test. *Machine Learning Research*, 2012, 13(1):723–773.
- [19] Dorri F, Ghodsi A. Adapting component analysis. In: *Proc. of the 12th IEEE Int 'l Conf. on Data Mining*. Brussels: IEEE, 2012. 846–851.

- [20] Zhang K, Schölkopf B, Muandet K, Muandet K, Wang ZK. Domain adaptation under target and conditional shift. In: Proc. of the 30th Int'l Conf. on Machine Learning. Atlanta: JMLR.org, 2013, 819–827.
- [21] Gong MM, Zhang K, Liu TL, Tao DC, Glymour C, Schölkopf B. Domain adaptation with conditional transferable components. In: Proc. of the 33rd Int'l Conf. on Machine Learning. New York: JMLR.org, 2016. 2839–2848.
- [22] Cao K, Tu ZP, Ming Y. Class conditional distribution alignment for domain adaptation. *Control Theory and Technology*, 2020, 18(1):72–80.
- [23] Pan SJ, Tsang IW, Kwok JT, Yang Q. Domain adaptation via transfer component analysis. *IEEE Trans. on Neural Networks*, 2011, 22(2): 199–210.
- [24] Tzeng E, Hoffman J, Zhang N, Saenko K, Darrell T. Deep domain confusion: Maximizing for domain invariance. arXiv:1412.3474, 2014.
- [25] Long MS, Zhu H, Wang JM, Jordan MI. Deep transfer learning with joint adaptation networks. In: Proc. of the 34th Int'l Conf. on Machine Learning. Sydney: JMLR.org, 2017. 2208–2217.
- [26] Yu CH, Wang JD, Chen YQ, Huang MY. Transfer learning with dynamic adversarial adaptation network. In: Proc. of the 2019 IEEE Int'l Conf. on Data Mining. Beijing: IEEE, 2019, 778–786.
- [27] Ganin Y, Lempitsky V. Unsupervised domain adaptation by backpropagation. *Proceedings of International Conference on Machine Learning*. In: Proc. of the 32nd Int'l Conf. on Machine Learning. Lille: JMLR.org, 2015, 1180–1189.
- [28] Saenko K, Kulis B, Fritz M, Darrell T. Adapting visual category models to new domains. In: Proc. of the 11th European Conf. on Computer Vision. Heraklion: Springer, 2010. 213–226.
- [29] Venkateswara H, Eusebio J, Chakraborty S, Panchanathan S. Deep hashing network for unsupervised domain adaptation. In: Proc. of the 2017 IEEE Conf. on Computer Vision and Pattern Recognition. Honolulu: IEEE, 2017. 5385–5394.
- [30] Sun B, Feng J, Saenko K. Return of frustratingly easy domain adaptation. *Proc. of the 2016 AAAI Conf. on Artificial Intelligence*, 2016, 30(1).
- [31] Saito K, Watanabe K, Ushiku Y, et al. Maximum classifier discrepancy for unsupervised domain adaptation. In: Proc. of the 2018 IEEE/CVF Conf. on Computer Vision and Pattern Recognition. Salt Lake City: IEEE, 2018. 3723–3732.
- [32] Wang H, Xu MH, Ni BB, Zhang WJ. Learning to combine: Knowledge aggregation for multi-source domain adaptation. In: Proc. of the 16th European Conf. on Computer Vision. Glasgow: Springer, 2020. 727–744.
- [33] Wang SS, Wang B, Zhang Z, Heidari AA, Chen HL. Class-aware sample reweighting optimal transport for multi-source domain adaptation. *Neurocomputing*, 2023, 523:213–223.
- [34] Cao ZJ, Ma LJ, Long MS, Wang JM. Partial adversarial domain adaptation. In: Proc. of the 15th European Conf. on Computer Vision. Munich: Springer, 2018. 139–155.
- [35] Cao ZJ, Long MS, Wang JM, Jordan MI. Partial transfer learning with selective adversarial networks. In: Proc. of the 2018 IEEE/CVF Conf. on Computer Vision and Pattern Recognition. Salt Lake City: IEEE, 2018. 2724–2732.
- [36] Cao ZJ, You KC, Long MS, Wang JM, Yang Q. Learning to transfer examples for partial domain adaptation. In: Proc. of the 2019 IEEE/CVF Conf. on Computer Vision and Pattern Recognition. Long Beach: IEEE, 2019. 2980–2989.