

多视角融合的时空动态图卷积网络城市交通流量预测^{*}

赵文竹¹, 袁冠^{1,2}, 张艳梅^{1,2}, 乔少杰³, 王森章⁴, 张雷⁵



¹(中国矿业大学 计算机科学与技术学院,江苏 徐州 221116)

²(矿山数字化教育部工程研究中心,江苏 徐州 221116)

³(成都信息工程大学 软件工程学院,四川 成都 610225)

⁴(中南大学 计算机学院,湖南 长沙 410083)

⁵(同济大学 上海自主智能无人系统科学中心,上海 201804)

通讯作者: 袁冠, E-mail: yuanguan@cumt.edu.cn

摘要: 城市交通流量预测是构建绿色低碳、安全高效的智能交通系统的重要组成部分.时空图神经网络由于具有强大的时空数据表征能力,被广泛应用于城市交通流量预测.当前时空图神经网络在城市交通流量预测中仍存在以下两方面局限性:1)直接构建静态路网拓扑图对城市空间相关性进行表示,忽略了节点的动态交通模式,难以表达节点流量之间的时序相似性,无法捕获路网节点之间在时序上的动态关联.2)只考虑路网节点的局部空间相关性,忽略节点的全局空间相关性,无法建模交通路网中局部区域和全局空间之间的依赖关系.为打破上述局限性,本文提出了一种多视角融合的时空动态图卷积模型用于预测交通流量.首先,从静态空间拓扑和动态流量模式视角出发,构建路网空间结构图和动态流量关联图,并使用动态图卷积学习节点在两种视角下的特征,全面捕获城市路网中多元的空间相关性.其次,从局部视角和全局视角出发,计算路网的全局表示,将全局特征与局部特征融合,增强路网节点特征的表现力,发掘城市交通流量的整体结构特征.接下来,设计了局部卷积多头自注意力机制来获取交通数据的动态时间相关性,实现在多种时间窗口下的准确流量预测.最后,在四种真实交通数据上的实验结果证明了本文模型的有效性和准确性.

关键词: 交通流量预测;多视角时空特征;图卷积网络;时空图数据;注意力机制

中图法分类号: TP311

中文引用格式: 赵文竹, 袁冠, 张艳梅, 乔少杰, 王森章, 张雷. 多视角融合的时空动态图卷积网络城市交通流量预测. 软件学报. <http://www.jos.org.cn/1000-9825/7018.htm>

英文引用格式: Zhao WZ, Yuan G, Zhang YM, Qiao SJ, Wang SZ, Zhang L. Multi-view Fused Spatial-temporal Dynamic Graph Convolutional Network for Urban Traffic Flow Prediction. Ruan Jian Xue Bao/Journal of Software (in Chinese). <http://www.jos.org.cn/1000-9825/7018.htm>

Multi-view Fused Spatial-temporal Dynamic Graph Convolutional Network for Urban Traffic Flow Prediction

ZHAO Wen-Zhu¹, YUAN Guan^{1,2}, ZHANG Yan-Mei^{1,2}, QIAO Shao-Jie³, WANG Sen-Zhang⁴, Zhang Lei⁵

¹(School of Computer Science and Technology, China University of Mining and Technology, Xuzhou 221116, China)

²(Mine digitalization Engineering Research Center of the Ministry of Education, Xuzhou 221116, China)

³(School of Software Engineering, Chengdu University of Information Technology, Chengdu 610225, China)

⁴(School of Computer Science and Engineering, Central South University, Changsha 410083, China)

⁵(Shanghai Research Institute for Intelligent Autonomous Systems, Tongji University, Shanghai 201804, China)

* 基金项目: 国家自然科学基金(62272461, 71774159, 61871686, 62272066); 博士后特别资助(2021T140707); 徐州市科技基金项目(KC22047)

收稿时间: 2023-05-11; 修改时间: 2023-07-07; 采用时间: 2023-08-24; jos 在线出版时间: 2023-09-11

Abstract: Traffic flow prediction is an essential component of environmental, safe, and efficient intelligent transportation system. Due to the powerful spatial-temporal data representation ability, spatial-temporal graph neural network is widely used in traffic flow prediction. However, existing spatial-temporal graph neural network based traffic flow prediction models have two limitations: 1) The static topology graph constructed from city spatial correlation ignores the dynamic traffic patterns, which are unable to reflect the temporal dynamic correlation between nodes in road network. 2) Only considering the spatial correlation of local traffic areas lacks the spatial correlations between the local region and the global road network. To overcome the above limitations, this paper proposes a multi-view fused spatial-temporal dynamic graph convolutional network model for traffic flow prediction. Firstly, it constructs a road network spatial structure graph and a dynamic traffic-flow association graph from the perspectives of static spatial topology and dynamic traffic patterns, and uses dynamic graph convolution to learn the node features from both perspectives, comprehensively capturing the diverse spatial correlations in the road network. After that, from the local and global perspectives, it calculates the global representation of the road network and fuses global features with local features to enhance the expressiveness of node features and explore the global structural features of traffic flow. Finally, the model designs a local convolutional multi-head self-attention mechanism to obtain the dynamic temporal correlation of traffic data, achieving accurate traffic flow prediction under multiple time windows. The experimental results on four real traffic data demonstrate the effectiveness and universality of the proposed model.

Key words: traffic flow prediction; multi-view spatial-temporal feature; graph convolutional network; spatial-temporal graph data; attention mechanism

近年来,数字城市智能化建设的快速发展对城市交通路网系统提出了更高的要求.城市规模不断扩大,人口数量的不断增加,带来城市交通系统的道路容量不足、交通堵塞等问题^[1].因此,针对城市路网连通复杂、流量分布失衡、路况动态变化等问题,研究面向城市路网系统的交通流量预测已经成为现阶段研究热点.交通流量预测能够根据历史的交通状况,提供连续、精确的道路未来状态信息,为城市规划和交通管理提供有效的决策支持,为城市居民出行路径规划提供信息支撑,实现缓解交通拥堵,绿色低碳出行的目的.

早期的城市交通流量预测系统大都基于统计学习模型和机器学习模型^[2,3].这些模型和方法难以捕捉城市路网中深层非线性的时空相关性,且严重依赖特征工程,无法有效地捕获路网数据的时空特性.为了建模交通流量的时间和空间特征,研究人员设计了各种神经网络模型解决交通领域的流量预测问题^[4-6].例如,Qu 等^[7]借助循环神经网络(Recurrent Neural Network, RNN)建模交通流量在时间维度的演化特征.Mo 等^[8]使用卷积神经网络(Convolutional Neural Network, CNN)捕获城市区域交通数据的空间关联特征.但这类方法只能学习欧式空间下的交通流量特征,难以表达具有复杂拓扑结构的城市路网.此外,RNN 还存在梯度爆炸或消失的问题,导致模型无法有效捕捉交通序列之间的长期依赖关系,不能准确的挖掘交通流量的时间演化特性.

为解决上述问题,一些学者将能够处理非欧式数据的图卷积网络(Graph Convolutional Network, GCN)引入到交通流量预测之中^[9-11].交通流量数据通常是在道路网络上的各个节点(如路口、路段等)上采集得到的,因此可以将城市路网抽象为一个图结构,其中节点表示路网中的交通节点,边表示节点之间的连接关系(道路等),GCN 通过对交通路网图进行卷积操作,学习节点之间的关系,实现交通流量预测,并取得了较好的预测效果.其中较为典型的图神经网络模型有 T-GCN,STGCN 等.T-GCN^[12]通过 GCN 学习路网复杂的拓扑结构捕获节点间的空间依赖关系.STGCN^[13]构建了由 GCN 和门控时间卷积组成的时空卷积层建模节点间的时空相关性等.然而,交通流量预测作为典型的时空数据预测问题,由于数据的时空特性和节点的复杂关联,流量预测仍存在以下问题和挑战:

(1)如何全面捕捉路网节点之间的时序相似性和动态时空相关性:大部分图卷积网络模型通过预先定义静态的城市路网图来描述节点之间的空间相关性,由于路网节点的交通流量会随时间和空间动态变化,这些静态图无法捕捉其动态特性,忽略了道路网络中的节点之间相似的功能特性以及动态交通模式的影响.以图 1 为例,在城市路网中,节点 1 和节点 5 在实际路网中并没有直接的道路相连且距离较远,但两个节点都位于功能相似的办公区域,因此呈现了相似的交通模式.两个节点在早晚高峰期都会发生相应程度的道路拥堵,而节假日期间道路交通流量相应减少.同样的,节点 4 和节点 6 位于相似的功能区域,具有相似的交通流量时序特征,而节点 1 和节点 6 距离较远,且位于不同的功能区域,节点之间较难建立动态关联.借助相似的流量时序特征,可以发现城市不同区域的功能相似性(相似的功能区域往往也具有相似的流量特性),对提升预测效果具有重要意义.

义.STFGNN^[14]在图卷积过程中考虑不同区域中交通流量的时序相似性,使用动态时间规划(Dynamic Time Warping, DTW)算法来计算节点之间的时序相似性,但 STFGNN 未充分考虑节点之间的动态时空相关性.

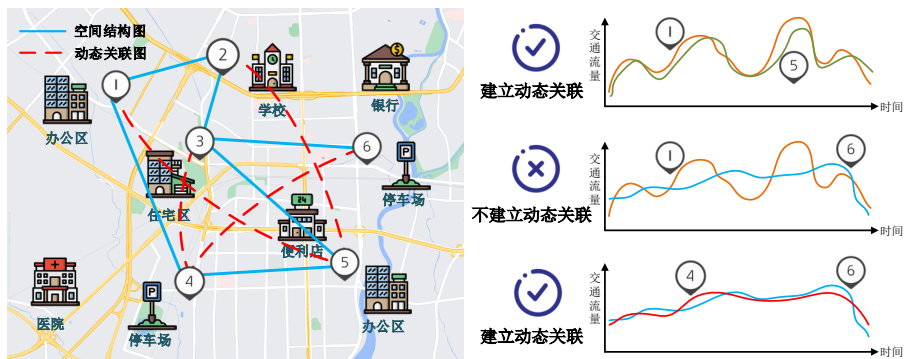


图1 交通路网中节点的空间相关性

(2)如何挖掘路网中局部空间结构和全局空间相关性之间的依赖关系:交通路网作为一个连通复杂且时空关联度高的网络结构,节点间的依赖关系不仅仅存在于局部区域,距离较远的节点之间仍具有相关性,节点之间的依赖(交互、关联)关系会影响至全局路网的交通状况,例如图2中节点6的交通流量过大,不仅会导致其周边节点3拥堵,同时会影响远距离节点2和节点5的交通状况,使得全局节点的交通状况发生变化.因此在建模交通数据空间相关性的同时,捕捉到路网局部空间结构和全局空间相关性之间的依赖关系,能够进一步提升交通预测的精度.然而,目前大多数交通流量预测模型仅关注路网中局部空间结构的相关性,忽略了全局空间的相关性,无法捕捉到路网中局部结构和全局相关性之间的依赖关系.

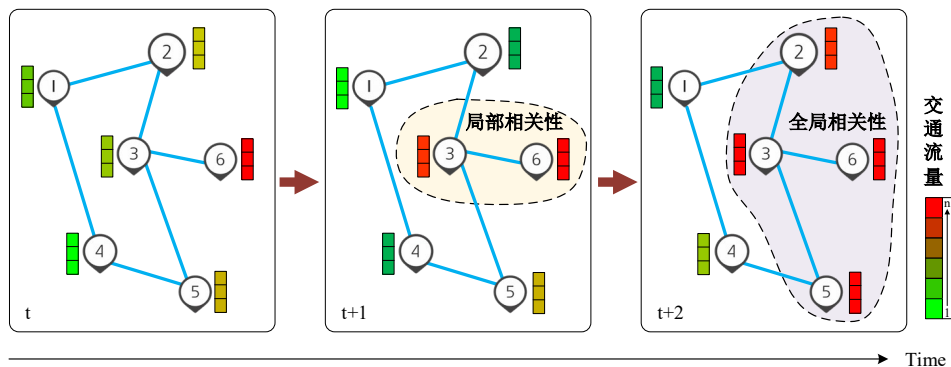


图2 交通路网中节点的全局相关性

针对上述的两个问题,本文提出了多视角融合的时空动态图卷积网络交通流量预测方法(Multi-view fused Spatial-Temporal dynamic Graph Convolutional Network, MVSTGCN),从空间关联性与时序相似性出发,全面地挖掘路网节点之间多元的空间关联,并学习路网的全局空间特征,捕捉路网节点中局部空间结构和全局空间相关性之间的依赖关系,实现准确的城市交通流量预测.首先,该方法从静态路网拓扑结构出发,构建空间结构图,根据时间序列相似度捕捉节点之间的时序相似性建立动态关联图,从静态的空间结构和动态的时序相似两个视角描述交通数据的空间相关性.然后,空间结构图和动态关联图将分别输入由自注意力机制构建的动态图卷积模块,实现动态空间相关性协同捕捉.同时从局部视角和全局视角捕捉空间相关性,引入路网的全局特征来表示城市整体的时空特性,捕获局部空间结构和全局空间特征的时空依赖.最后,利用上下文感知的局部卷积多头自注意力机制捕获交通流量的时间相关性,并通过解码模块预测城市未来交通流量状态.

本文的主要贡献如下:

(1)本文提出了一种多视角融合的时空动态图卷积交通流量预测模型 MVSTGCN,从静态路网和动态模式视角出发,分别构建空间结构图和动态关联图,并设计动态图卷积网络学习路网节点在空间结构图和动态关联图两种结构下的空间依赖特征,捕捉路网中的空间结构特性。

(2)MVSTGCN 从局部视角和全局视角出发,设计路网的全局时空特征学习模块,利用全局特征提取路网全局空间相关性,获得长期时空依赖关系,挖掘交通网络中全局空间相关性和局部动态之间的相互作用,提高了交通流量的预测性能,实现了有效的长期交通流量预测能力。

(3)选择了 11 种对比模型,其中 4 种非图卷积模型,7 种图卷积模型,并在四个真实的交通数据集上对本文模型的有效性进行实验验证.本文模型在四种数据集上的预测结果与最优图卷积模型相比,均有 4.8-14.8%的提升,证明了 MVSTGCN 在交通流量预测中的有效性。

本文的组织结构如下:本文第 1 节介绍交通预测和图卷积网络的相关工作.第 2 节提出多视角融合的时空动态图卷积网络框架.第 3 节通过对比实验验证所提模型的有效性和可解释性.第 4 节总结全文并提出展望。

1 相关工作

近年来,交通流量预测的研究受到广泛关注并取得了一定进展.现有的交通流量预测从技术的角度主要可以分为以下三种:基于浅层模型的流量预测方法、基于卷积神经网络的流量预测方法以及基于图神经网络的流量预测方法。

1.1 基于浅层模型的交通流量预测

浅层模型的预测方法可大致分为基于统计的方法与基于传统机器学习的方法.基于统计的方法是通过建立统计模型,对数据进行预测和分析.早期具有代表性的方法包括历史平均法^[15](Historical Average, HA)、自回归综合移动平均法^[16](Auto-Regressive Integrated Moving Average, ARIMA)、卡尔曼滤波法^[17]等.HA 以历史一段时间交通数据的均值为依据,模拟未来交通趋势.ARIMA 及其扩展方法是要求时间序列达到弱平稳,然后使用数学模型拟合历史数据,来预测时间序列中的未来点.卡尔曼滤波法是根据现有数据形成对下一个观测值的最佳预测模型.基于统计的方法框架简单,计算方便,但需假设交通静止,且无法处理非线性数据,面对如今数据量大、复杂且非线性的交通流量数据,其处理能力不足^[18]。

由于基于统计模型的诸多不足,许多传统机器学习方法被应用于交通流量预测领域,例如 K 最近邻模型(K-nearest Neighbor, KNN)^[19]、支持向量回归(Support Vector Regression, SVR)^[20]等.KNN 是一种简单、直观、易于实现且应用范围广的监督非参数机器学习算法,通过搜索与当前变量值匹配的 K 个最近邻,并使用该 K 个数据来预测下一个周期的值.SVR 建立一个超平面作为给定训练样本的决策面,使所有样本点都接近超平面,并使样本点与超平面的总偏差最小.基于结构风险最小化原理的 SVR 与其他非线性预测模型相比,避免了容易陷入局部最优的缺点.基于传统机器学习的交通流量预测方法相较于基于数理统计的方法具有更高的预测精度,建模时对不同交通模式之间关系的先验知识需求较少,无需对预测任务添加过多限制,但需人工提取特征,严重依赖特征工程,同时无法很好的建模交通数据间复杂的时空相关性^[21]。

1.2 基于卷积神经网络的交通流量预测

深度学习作为机器学习的子领域,由于其在计算机视觉^[22]、自然语言处理^[23]等领域中表现出强大的特征提取能力,让深度神经网络逐渐被应用至交通流量预测之中.其中多种基于卷积神经网络的流量预测方法被提出以捕捉交通数据的空间相关性.早期的深度学习方法将道路网络或整个城市划分为规则网格,构建不同区域间的欧式关系,预测网格内的交通流量,并使用卷积神经网络提取空间特征,如 Zhang 等^[24]利用带有残差结构的 CNN 网络,分别动态聚合时间邻近性,周期性,趋势性三个时间特性,并将三个 CNN 的输出与外部因素结合,预测每个地区的人群流量.Li 等^[6]提出了深度时空自适应 3D CNN 实现交通流量预测,通过自适应 3D 卷积模块同时捕捉时空关系,根据历史数据影响灵活分配不同的权重,并通过外部特征嵌入模块捕获外部因素对流量的影

响.Zheng 等^[25]将 CNN 与长短时记忆单元(Long Short-Term Memory, LSTM)结合使用,CNN 学习空间上的 2D 流量数据,LSTM 从时间序列上建模时间相关性,同时增加嵌入模块捕获天气和路线结构的特征信息.上述方法通过将城市或区域建模为规则网格,使用 CNN 获取空间相关性,虽然 CNN 具有较好的特征学习能力,但只能应用于欧式数据,而现实生活中的交通网络结构是具有复杂拓扑结构的非欧式数据,无法从本质上表征交通网络的空间依赖特性.

1.3 基于图神经网络的交通流量预测









图神经网络成功地将卷积操作推广至非欧式结构的图数据,能有效的提取拓扑结构的特征,广泛的应用于社交网络^[26]、知识图谱^[27]、推荐系统^[28]等领域.为解决 CNN 无法捕捉路网拓扑结构特征的问题,研究人员提出了基于图神经网络的交通流量预测模型.表 1 总结了使用 GCN 进行交通流量预测的模型,其中 DCRNN^[29]将交通流建模为有向图上的扩散过程,使用双向图随机游走建模空间依赖性,并通过 RNN 捕获时间动态性.STGCN^[13]构造了多个时空卷积模块,每个时空卷积模块包含空间图卷积和门控序列卷积层,分别用于提取空间特征和时间特征,有效的建模了交通网络的连通性与全局性.Zhao 等^[12]集成了 GCN 和门控递归单元(Gate Recurrent Unit, GRU),GCN 用于学习复杂的拓扑结构捕获空间依赖,GRU 用于学习交通数据的动态变化来捕获时间依赖.上述方法通过组合学习空间结构的 GCN 和提取时间信息的 RNN 或 CNN,捕捉路网的时空依赖关系.然而这些方法依然无法捕捉交通数据的动态相关性和不同周期模式.因此 Guo 等^[30]提出了基于注意力的时空图卷积网络(ASTGCN).ASTGCN 由交通流量的近期、日周期和周周期依赖三个独立组件组成,使用时空注意力机制有效捕获交通数据的动态相关性.Zheng 等^[31]提出了使用门控融合的时空注意力机制来模拟动态时空相关性,转换注意力机制来缓解误差传播的影响以实现长期预测性能的图多注意网络(GMAN).为了有效捕捉交通数据的动态特性和空间异质性,Guo 等^[32]进一步提出了基于时间感知多头自注意力机制和动态图卷积模块的时空图神经网络(ASTGNN).上述方法捕获空间相关性主要依赖预定义的静态图结构,忽略了节点之间潜在的动态相关性信息.因此一些新的构建图结构的方法被提出,Graph WaveNet^[33]和 AGCRN^[34]通过自适用图结构捕捉隐藏的空间依赖性,STGODE^[35]将常微分方程(Ordinary Differential Equation, ODE)引入 GCN,构建静态空间邻接矩阵,然而这些模型没有明确考虑路网节点之间的动态时空依赖性.


表 1 时空相关网络模型分类

模型	空间相关性	时间相关性	图节点关系构建
DCRNN ^[29]	GCN	GRU	预定义图
STGCN ^[13]	GCN	GLU	预定义图
T-GCN ^[12]	GCN	GRU	预定义图
GMAN ^[31]	注意力机制	注意力机制	预定义图
ASTGCN ^[30]	GCN+注意力机制	1D CNN+注意力机制	预定义图
ASTGNN ^[32]	GCN	注意力机制	预定义图
Graph WaveNet ^[33]	GCN	TCN	自适应图
AGCRN ^[34]	GCN	GRU	自适应图
STGODE ^[35]	ODE+GCN	TCN	动态图

2 方法

2.1 问题定义

定义 1.交通网络:本文将交通网络分别表示为空间结构图和动态关联图,其中为节点集,为节点个数,每个节点代表一个交通观测点,例如传感器或地铁网络站点的刷卡机.空间结构图和动态关联图共享相同的节点,但具有不同的边和边权重.和表示不同图的边集,和分别表示空间结构图和动态关联图相应的邻接矩阵.

定义 2.交通流量矩阵:以交通网络中节点为信号采集点,在 t 时刻采集的观测值被定义为交通流量矩阵

其中 \mathbf{X}_t 定义为节点 i 在时刻 t 的特征向量, N_i 为观测值的取值数量,例如 N_i 为2时,观测值为交通流入和流出数据。

定义 3. 交通流量预测:给定过去 L 个时间片的历史时空交通流量矩阵 $\mathbf{X}_{t-L:t}$,交通流量预测的目标是从历史交通流量观测值中学习映射函数 f ,结合交通网络 \mathbf{G} 上的 K 个相关观测点去预测未来 L 个时间步的交通流量矩阵 $\mathbf{X}_{t:t+L}$ 。

2.2 多视角融合的时空动态图卷积网络

本文提出了一种多视角融合的时空动态图卷积网络交通流量预测方法(Multi-View fused Spatial-temporal dynamic Graph Convolutional Network, MVSTGCN),分别从空间维度和时间维度建模路网中复杂的动态时空相关性,实现准确的交通流量预测.MVSTGCN 采用在输入数据上嵌入特征的编码器-解码器框架,编码器和解码器分别由多层相同的编码器层和解码器层堆叠而成,主要包含空间多视角动态图卷积模块和时间局部卷积多头自注意力机制模块.原始输入交通数据通过嵌入模块捕获交通数据的空间异质性和顺序信息,时间局部卷积多头自注意力捕获包含局部趋势信息的时间动态相关性.在空间多视角动态图卷积模块中,设计空间结构图和动态关联图分别捕捉交通路网节点的静态信息和动态模式,引入自注意力机制捕获空间节点隐藏的动态关联,从全局视角引入全局表示建模全局空间相关性.为了保证随着模型的深入能够进行有效训练,每一层都添加了残差连接和层归一化,将捕获的特征通过线性层输出预测的交通序列.本文的整体框架如图3所示。

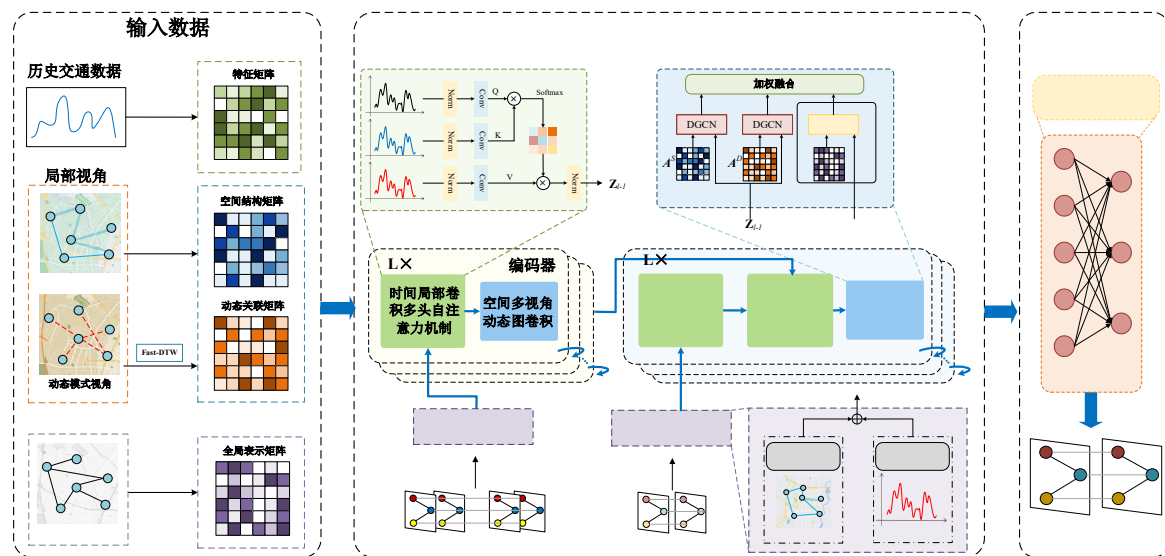



图3 本文研究框架

2.3 交通图构建

传统的图卷积网络模型通过预先定义的静态城市路网图来描述节点之间的空间相关性,节点间的距离代表了地理位置上的邻近性与连通性,一般来说节点距离越近,其交通模式越接近,但节点间的距离并不能完全反映其空间依赖特性.本文基于静态的空间结构和动态的时序相似分别构建了空间结构图和动态关联图,利用双视图来提取不同区域之间的双视角时空关联,在空间结构图的基础上构建动态关联图,通过表征节点间相似的城市功能特性以及动态交通模式的影响,提取更为准确的动态空间依赖性。

(1)空间结构图:空间结构图是基于现实静态路网距离和阈值高斯核(thresholded Gaussian kernel)^[36]而构建,准确记录了节点之间的空间位置关系.节点 i 和 j 之间的距离矩阵 \mathbf{D}_{ij} 具体定义如下:



其中 d_{ij} 代表节点 i 和节点 j 之间的距离, θ 为控制矩阵 D 分布的阈值, δ 为控制邻接矩阵稀疏性的阈值。

(2)动态关联图:动态关联图是基于节点之间的时间序列相似性,通过考虑节点之间相似的功能特性以及交通模式的动态影响所构建的交互图。例如类似的商业区附近存在相似的交通模式,在空间中可能不存在连接关系的节点,但由于其功能特性相似,在动态关联图上就会存在交互。为了捕获节点之间的相似性,使用 DTW 算法^[37]计算两个时间序列相似度。DTW 算法是通过一对多以及多对一匹配的方式使得两个时间序列之间总距离最小化的最优匹配方法,且由于其对形状相似性而非点状相似性的敏感性,令该算法优于其他相似度计算方法。具体而言,给定两个时间序列 X 和 Y ,序列之间的距离定义为:

$$D(X, Y) = \min_{\pi} \sum_{(i, j) \in \pi} d(x_i, y_j) \quad (3)$$

其中 $D(X, Y)$ 表示两个时间序列 X 和 Y 之间的最短距离, $d(x_i, y_j)$ 为任意经典距离度量,例如绝对距离。算法核心是求解扭曲曲线。因此 $D(X, Y)$ 被设定为时间序列 X 和 Y 之间的最终距离,与欧氏距离相比,它更能反映两个时间序列的相似性。

然而使用 DTW 算法计算序列相似度需获得 $D(X, Y)$ 等计算项,即计算 $D(X, Y)$ 需要得到整个 D 矩阵以确保找到最优答案,算法的时间复杂度为 $O(L^2)$,当时间序列较长时,DTW 算法效率过低。因此本文使用了 Fast-DTW 算法^[38],该算法基于 DTW 算法,可以处理大规模时间序列,通过使用多级方法避免了标准 DTW 算法中的暴力动态规划方法来确定两个时间序列的相似性和对应区域。Fast-DTW 算法结合了限制和数据抽象两种方法来加速 DTW 的计算,具体分为以下三个步骤:




图 4 Fast-DTW 算法流程

粗化:将原始的时间序列进行粗化,即对原始的时间序列进行数据抽象,形成一个新的、更粗糙的时间序列,以更少的数据点尽可能准确地表示同一曲线。

投影:在较粗粒度上使用 DTW 算法,即在较低维度下计算最小距离扭曲路径,并将获得的扭曲路径投影至较高维度时间序列,为较高维度序列构建一个扭曲带。

细化:通过局部调整以优化扭曲路径,即在先前构建的扭曲带中再次计算扭曲路径。

Fast-DTW 算法重复投影和细化步骤,直到获得最终序列的扭曲路径并计算出最佳扭曲路径的实际 DTW 距离。由于该算法成本矩阵仅填充较低维度投影路径的附近,扭曲路径的长度随时间序列的长度线性增长,将算法的时间复杂度由 $O(L^2)$ 降为 $O(L)$,使得其在大规模空间时间数据集上的应用成为可能。

通过 Fast-DTW 算法构造节点 i 和 j 之间的动态关联矩阵 A_{ij} ,定义 A_{ij} 为:

$$A_{ij} = \begin{cases} 1 & \text{if } d(x_i, y_j) \leq \delta \\ 0 & \text{otherwise} \end{cases} \quad (4)$$

其中 x_i 和 y_j 分别表示节点 i 和节点 j 的时间序列, δ 为控制邻接矩阵稀疏性的阈值。

2.4 编码器结构

模型整体框架采用在输入数据上嵌入特征的编码器-解码器框架,编码器和解码器均由多层相同的编码器

层和解码器层堆叠而成.编码器-解码器结构可以将交通预测问题转化为序列到序列的映射问题,将历史的交通流量数据作为输入,通过编码器提取时空特征,再通过解码器生成未来的交通流量数据.编码器和解码器中的注意力机制均可以并行操作,增强模型的时空相关性学习能力,捕捉交通序列中不同时间步之间的依赖关系.编码器-解码器结构可以有效处理交通序列数据,并且能够捕捉时序数据中的长期依赖关系,同时可以处理不同长度的输入和输出序列,具有较好的泛化能力.

编码器由 L 个完全相同的编码器层堆叠而成,每层均包含两个基本模块:时间局部卷积多头自注意力模块、空间多视角动态图卷积模块.时间局部卷积多头自注意力模块在时间维度上建模交通数据的时间依赖关系,空间多视角动态图卷积模块在空间维度上捕获交通数据的空间交互特性和时序相似交互特征,并引入全局表示建模局部特征与全局特征的关联关系.同时为了避免随着编码器层数增加而出现的梯度消失现象,添加了残差网络和层归一化,使得网络更快收敛,提高模型的泛化能力.

2.4.1 时间局部卷积多头自注意力模块

为了在时间维度捕获交通数据的动态时间相关性,本文在时间模块使用注意力机制捕捉时间依赖关系的动态特征.注意力机制有助于从输入交通数据中选择和聚焦与当前预测目标最相关的时间特征,提高模型的性能和效果,可以被描述为将查询 Q 和一组键值对 (K, V) 映射到某个输出的过程,其中 Q 表示当前时间步的特征向量, K 用于计算输入交通序列中每个元素与 Q 的相似度, V 是与 Q 关联的向量,在计算了 Q 与每个 V 的相似度之后,这些相似度值被用作权重,对应的 V 向量加权求和,得到最终的输出.其中较为常用的两种注意力函数分别为:加和式注意力函数(Additive attention)和缩放点积式注意力函数(Scaled dot-product attention),点积注意力作为更为广泛使用的注意函数,具有更高的计算效率和更好的表达能力.本文中使用的缩放点积式注意力机制, Q 是查询向量和值向量的维度,具体可表示为:

$$\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (5)$$

自注意力机制(Self-attention)是一种查询 Q 、键 K 和值 V 均相同的特殊注意力机制,通过捕捉输入序列中不同位置之间的相关性和动态调整注意力权重,提高模型的表达能力和灵活性,具体的实现过程如图 5(a),但模型在对当前位置的信息进行编码时,会过度的将注意力集中于自身的位置.

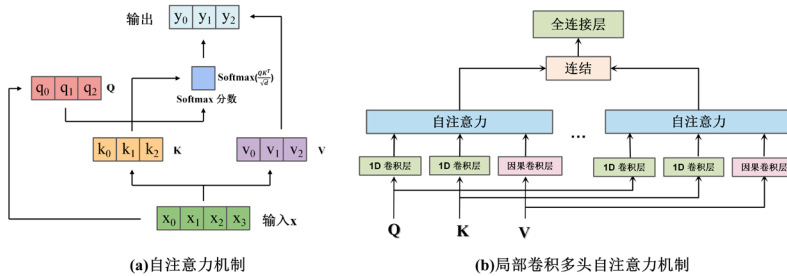


图5 自注意力机制与局部卷积多头自注意力机制

多头自注意力机制(Multi-Head Self-attention)给予注意力层输出关注来自不同位置的不同表示子空间的编码表示信息,以并行而非顺序的方式处理时间序列,能够最大限度地减少长期依赖问题和时间步长累积误差问题.首先将查询、键和值线性投影到不同的表示子空间,然后并行执行多组自注意力处理,最后将每组自注意力机制的输出汇聚拼接并进行一次线性变换,产生最终的输出结果,计算公式如下.

$$\text{Multi-Head Self-attention}(Q, K, V) = \text{Concat}(\text{Head}_1, \text{Head}_2, \dots, \text{Head}_h)W^O \quad (6)$$

$$\text{Head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \quad (7)$$

其中 h 代表注意力模块(头)的数量, W_i^Q, W_i^K, W_i^V 分别代表在 Q, K, V 上的投影矩阵, W^O 代表最终输出的投影矩阵, Concat 代表拼接操作.多头自注意力机制可以充分考虑序列中不同位置之间的关系,允许建模序列中元

素的相关性,从而更好地捕获交通数据中长期依赖关系,通过堆叠多个自注意力层学习不同层次的特征表示,有效捕捉交通数据中的复杂模式和动态关系,实现精准的交通长期预测。




图6 交通观测点连续序列点值相似度匹配和局部相似度匹配比较

交通序列模式会随时间显著地演变,且易受节假日、交通事故、极端天气等事件影响.因此判断观测点是寻常模式还是存在异常需要充分结合路网局部结构信息.传统的多头自注意力机制在自然语言处理领域用于处理离散的标记序列,因此自注意力模块中查询和键之间的相似度是基于点值计算,忽略了形状、趋势等局部上下文信息,无法学习连续时间序列中固有的局部趋势信息和因果关系.图6显示了某一交通观测点的连续交通信号序列,由于传统的自注意力机制是基于点值相似度匹配,会错误的将A点与B点相匹配,然而A点和B点虽然在数值上相同却具有不同的局部趋势和特征,B点和C点虽然数值上不同却具有相同的局部趋势和特征,即都处峰值阶段.简单的将传统多头自注意力机制应用于交通信号序列处理,局部上下文的不匹配可能会导致错误的交通序列表示,并带来底层优化问题,影响最终交通预测性能。

为了解决传统多头自注意力机制在交通数据预测中无法感知局部趋势的问题,本文引入了可以匹配局部最相关特征的时间局部卷积多头自注意力机制,来探究交通序列的时间动态性.如图6(b)所示,利用卷积操作的局部感知特性,使用1D时序卷积计算替换查询和键上的线性投影.该卷积核在卷积操作时只关注输入中的局部区域,使得模型能够捕捉交通数据中的局部趋势特征以及序列数据中的短期相关性.为了避免在MVSTGCN的学习过程中,将未来时序信息暴露给模型,影响预测结果,本文使用了因果卷积操作,令MVSTGCN只学习流量数据中的当前位置及之前信息,掩盖当前位置之后信息,更好的捕捉因果关系而不受到未来信息的干扰.局部卷积多头自注意力机制的形式化定义如下。

$$\text{LCSelfMultiHead}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Concat}(\text{LCHead}_1, \dots, \text{LCHead}_h) \mathbf{W}^O, \quad (8)$$

$$\text{LCHead}_i = \text{Attention}(\mathbf{Q} \otimes \Phi_i^Q, \mathbf{K} \otimes \Phi_i^K, \mathbf{V} \otimes \Psi_i^V), \quad (9)$$

其中 Φ_i^Q, Φ_i^K 为1D卷积核参数, Ψ_i^V 为因果卷积核参数, \otimes 表示卷积运算.第 $l+1$ 层编码器输入为 \mathbf{X}_l , 所有节点上进行时间局部卷积多头自注意力操作之后,得到序列的中间表示 $\mathbf{Z}_l = (\mathbf{Z}_{l,t-m+1}, \mathbf{Z}_{l,t-m+2}, \dots, \mathbf{Z}_{l,t})$. 通过局部卷积自注意力机制,预测模型可以准确地建模交通数据在时间维度的动态性。

2.4.2 空间多视角动态图卷积

由于交通道路网络是以交通观测点为节点,以道路为边的图结构,所以图卷积网络可以自然的用于提取路网中的空间模式和特征.本文设计了双视角下的动态图卷积网络,用于学习路网中多元的空间相关性.原始的图卷积学习过程如下所示:

$$\mathbf{H}_{l+1} = \text{GCN}(\mathbf{H}_l) = \sigma(\mathbf{A}\mathbf{H}_l\mathbf{W}), \quad (10)$$

$$\mathbf{A} = \begin{cases} \tilde{\mathbf{D}}^{-\frac{1}{2}} \tilde{\mathbf{A}} \tilde{\mathbf{D}}^{-\frac{1}{2}}, & \text{undirected graph} \\ \tilde{\mathbf{D}}^{-1} \tilde{\mathbf{A}}, & \text{directed graph} \end{cases}, \quad (11)$$

其中 \mathbf{H}_l 表示第 l 个图卷积层的输入, σ 为激活函数, $\tilde{\mathbf{A}} = \mathbf{A} + \mathbf{I}$, \mathbf{A} 为邻接矩阵, \mathbf{I} 为单位矩阵, $\tilde{\mathbf{D}}$ 为 $\tilde{\mathbf{A}}$ 的度矩阵, \mathbf{W} 是可学习的权值矩阵.如图7所示,由于原始的图卷积模型只能用于学习静态图中的空间关联关系,无法捕捉实际路网中的节点之间的动态空间相关性,因此不能直接将原始的图卷积网络用于动态路网的学习之中。




图7 节点的动态空间依赖性

为了捕捉路网中的节点之间的动态空间关联,本文设计了空间双视角下的动态图卷积,利用自注意力机制动态计算节点间的空间相关性强度,自适应地调整节点间的连接关系.给定节点的表示以及时间局部卷积多头注意力的输出 \mathbf{Z}_l ,空间注意力相关性权重矩阵的计算如下所示:

$$\mathbf{S}_{att} = \text{softmax}\left(\frac{\mathbf{Z}_l \mathbf{Z}_l^T}{\sqrt{d_{\text{model}}}}\right) \in \mathbb{R}^{N \times N}, \quad (12)$$

其中 $\mathbf{S}_{att}(i, j)$ 表示节点 i 和 j 之间的相关性强度, \mathbf{S}_{att} 取值越大表示节点间相关性强度越大.通过空间注意力相关性权重矩阵调节邻接矩阵 \mathbf{A} ,得到动态图卷积模块的输出.动态图卷积的计算公式如(13),图8展示了动态图卷积的构建步骤.在所有路网节点上进行时间局部卷积多头自注意力操作之后,得到序列的中间表示 $\mathbf{Z}_l = (\mathbf{Z}_{l,t-m+1}, \mathbf{Z}_{l,t-m+2}, \dots, \mathbf{Z}_{l,t})$ 并以此为输入,进行动态图卷积计算.

$$\text{DGCN}(\mathbf{Z}_l) = \sigma((\mathbf{A} \square \mathbf{S}_{att}) \mathbf{Z}_l \mathbf{W}), \quad (13)$$




图8 动态图卷积

其中 \square 表示 Hadamard 乘积,空间动态图卷积直接使用邻接矩阵 \mathbf{A} ,只考虑单一的交通路网静态结构,忽略了节点之间相似的功能特性以及动态交通模式的影响,因此引入了空间结构矩阵 \mathbf{A}^S 和动态关联矩阵 \mathbf{A}^D ,分别捕获交通数据中静态空间相关性和动态时序相似性.并基于双视角的交通图矩阵,进一步构建了空间结构图卷积模块和动态关联图卷积模块.

$$\mathbf{X}_{l+1}^S = \text{SDGCN}(\mathbf{Z}_l) = \sigma((\mathbf{A}^S \square \mathbf{S}_{att}) \mathbf{Z}_l \mathbf{W}), \quad (14)$$

$$\mathbf{X}_{l+1}^D = \text{DDGCN}(\mathbf{Z}_l) = \sigma((\mathbf{A}^D \square \mathbf{S}_{att}) \mathbf{Z}_l \mathbf{W}). \quad (15)$$

经过空间双视角下的动态图卷积,进行空间结构图卷积和动态关联图卷积操作,并输出空间结构图卷积结果 $\mathbf{X}_{l+1}^S = (\mathbf{X}_{l+1,t-m+1}^S, \mathbf{X}_{l+1,t-m+2}^S, \dots, \mathbf{X}_{l+1,t}^S)$ 和动态关联图卷积结果 $\mathbf{X}_{l+1}^D = (\mathbf{X}_{l+1,t-m+1}^D, \mathbf{X}_{l+1,t-m+2}^D, \dots, \mathbf{X}_{l+1,t}^D)$.MVSTGCN 能够捕捉路网节点之间的静态空间关联关系以及隐藏的时序动态关联关系,令学习得到的节点表征同时包含了静态地理空间信息和动态时序语义信息,可以有效挖掘交通路网中的静态空间特性与动态时序模式.

2.4.3 全局表示学习模块

从节点的全局视角出发,本文提出了路网的全局表示学习模块用于捕获路网中不同节点之间的全局空间相关性.交通数据的空间相关性不仅存在于邻近的节点之间,以整个道路网络而言,长距离跨度的节点之间也存在空间相关性,例如城市交通重要节点发生堵塞时,不仅会影响邻近节点的交通状况,同时会影响较远距离节点的交通状况,从而导致路网全局节点交通流量的变化.因此本文使用皮尔逊相关系数来分析交通网络中节点之

间的全局空间相关性.对于路网中任意节点 i 和 j , 构建二者之间的全局相关性矩阵 $\mathbf{A}_{ij}^G \in \mathbb{R}^{N \times N}$, 表示如下:

$$\mathbf{A}_{ij}^G = \frac{\sum_{t=1}^T (x_{t,i} - \bar{X}_i)(x_{t,j} - \bar{X}_j)}{\sqrt{\sum_{t=1}^T (x_{t,i} - \bar{X}_i)^2} \sqrt{\sum_{t=1}^T (x_{t,j} - \bar{X}_j)^2}}, \quad (16)$$

其中 $X_i = (x_{1,i}, x_{2,i}, \dots, x_{t,i})$ 为节点 i 在 t 时间段内的交通流量特征, \bar{X}_i 为 X_i 的平均值.通过设置相关性阈值 k 选择高相关性的节点对.若节点之间的相关性度量大于 k , 则保持其相关性度量值, 反之表示为 0.




图9 路网全局表示学习

路网的全局表示学习使用图卷积对高相关度的节点特征进行聚合, 建模路网全局范围内的节点空间相关性.全局相关矩阵所描述的节点关系为有向加权图, 如图9所示.节点之间的权重表示空间影响大小, 边方向为影响关系.路网的全局表示学习计算如下:

$$\mathbf{X}_{l+1}^G = \text{GCN}(\mathbf{X}_l, \mathbf{A}^G) = \sigma(\mathbf{A}^G \mathbf{X}_l \mathbf{W}_l^G), \quad (17)$$

为了分析交通流量信号在路网全局空间与局部空间传播的动力学特性间的作用和关系, 本文将学习得到的路网全局表示与空间动态图卷积模块和时序动态图卷积模块的输出进行加权融合, 实现多元空间特征与全局特征的节点表示.融合操作的定义如下:

$$\mathbf{X}_{l+1} = \alpha(\tau \mathbf{X}_{l+1}^S + (1-\tau) \mathbf{X}_{l+1}^D) + (1-\alpha) \mathbf{X}_{l+1}^G, \quad (18)$$

其中 $\alpha, \tau \in [0, 1]$, α 为全局表示的融合比例, τ 为两种图表示的融合比例, 经过融合操作得到空间多视角动态图卷积模块的输出 $\mathbf{X}_{l+1} = (\mathbf{X}_{l+1,t-m+1}, \mathbf{X}_{l+1,t-m+2}, \dots, \mathbf{X}_{l+1,t})$.

空间多视角动态图卷积模块不仅可以探索路网中节点的距离信息和功能相似特性, 捕捉节点之间隐藏的空间相关性, 而且能够基于交通流量数据动态拟合流量在节点之间随时间变化的动态相关性.同时利用路网全局表示模块建模节点之间的全局空间相关性, 通过融合操作计算路网全局空间相关性和流量局部传播动力学之间的相互作用.

2.5 解码器结构

解码器由 L 个完全相同的解码器层堆叠而成.与编码器不同, 每个解码器层由两个时间局部卷积多头自注意力模块和一个空间多视角动态图卷积模块组成.基于编码器的输出 $\mathbf{X}_L = (\mathbf{X}_{L,t-m+1}, \mathbf{X}_{L,t-m+2}, \dots, \mathbf{X}_{L,t})$, 解码器部分使用另外 L 个解码层预测未来的时空交通流量序列 $\mathbf{Y}_L = (\mathbf{X}_{L,t+1}, \mathbf{X}_{L,t+2}, \dots, \mathbf{X}_{L,t+n})$.第一个时间局部卷积多头自注意力模块用来捕获解码器序列中的时序相关性, 第二个时间局部卷积多头自注意力模块用来捕获编码器输出序列和解码器序列之间的相关性, 生成的未来序列输入全连接网络映射至指定维度, 最后输出指定未来预测步长的预测序列 $\mathbf{Y} = (\mathbf{X}_{t+1}, \mathbf{X}_{t+2}, \dots, \mathbf{X}_{t+n}) \in \mathbb{R}^{N \times n}$.

2.6 时空嵌入模块

MVSTGCN 利用时间局部卷积多头自注意力模块和空间多视角动态图卷积模块, 有效地获取路网中的节点的时空动态特性, 但忽略了空间异质性和时间序列的顺序信息.

在空间上, 未来的交通状态不仅受到动态变化的交通条件影响, 同时受到底层道路网络静态特征的限制, 静态特征主要由节点的局部拓扑结构和相应的道路类型(如高速公路、城市公路、社区街道等)等空间特征决定.

节点的静态特征一般不随时间变化,但受到空间变化的影响,产生了节点的空间异质性,例如高速公路上的车辆行驶速度往往比生活街道上车辆的行驶速度快得多.因此捕捉节点的空间异质性,能够有效提升交通预测的准确性.受到 ASTGNN 模型[32]的启发,本文提出一种空间嵌入方法,首先为每个节点分配一个额外的嵌入向量,从而得到初始空间位置嵌入矩阵,然后应用图卷积层进行拉普拉斯平滑,使得每个节点与邻居节点具有相似表示,在反映图结构信息的同时构建异质空间结构,最终得到空间嵌入矩阵 E_{Sp} .

在时间上,交通流量数据的时间动态特性借助自注意力机制进行捕获,自注意力模型以同时处理整个时间序列,无法考虑时间序列的顺序信息.然而在交通流量预测任务中,邻近的观测数据往往具有更强的相关性,例如预测晚高峰的交通流量,相邻一小时的交通状况相比于相邻两小时的交通状况提供了更有用的信息,因此顺序信息在时间序列建模中至关重要.为了有效建模时间序列的顺序信息,本文使用 Transformer 的时间嵌入方法^[39],给初始序列每个元素都添加一个时间位置嵌入向量,使得相邻元素具有相近的表征.为位置 t 处的输入元素选择固定位置嵌入,得到时间嵌入矩阵 E_{TP} 并且每个向量维度 $1 \leq d \leq d_{\text{model}}$ 如下所示:

$$E_{TP}(t, 2d) = \sin(t / 10000^{2d/d_{\text{model}}}), \quad (19)$$

$$E_{TP}(t, 2d + 1) = \cos(t / 10000^{2d/d_{\text{model}}}), \quad (20)$$

其中 t 是输入中每个元素的相对索引.将空间嵌入矩阵 E_{Sp} 和时间嵌入矩阵 E_{TP} 添加至交通流量序列之中, MVSTGCN 就得到了保留了节点空间异质性与时间序列顺序特征的交通流量序列:

$$\mathbf{X}_{Sp+TP} = \mathbf{X} \oplus E_{TP} + E_{Sp}. \quad (21)$$

3 实验分析

为了验证本文方法的有效性,我们在四个真实的高速公路流量数据集和城市地铁人群流量数据集上进行实验.本节首先对数据集和实验设置进行介绍说明,然后将本文方法与基于统计方法和深度学习方法的 11 种方法进行对比分析,最后进行消融实验与内部分析,以验证本文方法中每个模块的有效性.

3.1 数据集

本文使用的高速公路流量数据集是由 Caltrans Performance Measurement System(PeMS)^[40]收集的美国加利福尼亚州四个地区的真实高速公路流量数据,分别是 PEMS03、PEMS04、PEMS07 和 PEMS08. PeMS 提供了由加州运输公司在加州高速公路上实时采集的高速公路流量数据集,以及其他加州运输公司和合作机构收集的统一交通数据库.道路的检测器每 30 秒报告一次数据,以 5 分钟为间隔进行聚合,一天的交通数据流中包含 288 个数据点,其中记录了传感器站的地理信息以及带时间戳的车流量、平均车速、平均车道占用率 3 个维度的特征.

城市地铁人群流量数据集为杭州城市内地铁网络上的人群流量数据集,该数据集使用 2019 年 1 月收集的杭州地铁系统交易记录创建,其中涉及 3 条线路 80 个运营站约 7000 万条数据,每天有 235 万乘客,原始人群流量数据被汇总为以 5 分钟为时间间隔的采样点,每条记录包含流入人群量和流出人群量.

两种城市流量数据集展现出不同的时空特性,高速公路流量数据集由高速公路上分布的检测器实时收集,节点之间具有较强的空间相关性,而城市地铁人群流量数据集由杭州地铁系统交易记录创建,仅包含了人群的进出站信息,因此节点之间的空间相关性较弱.在具有不同时空特性的数据集上验证本文方法的预测性能,增加实验结果的代表性和泛化能力,数据集详细信息如表 2 所示.

表 2 数据集描述

数据类型	数据集	区域(传感器)数量	边数量	时间步长	缺失比例	时间跨度
高速路网车流量	PEMS03	358	547	26208	0.672%	09/01/2018-11/30/2018
	PEMS04	307	340	16992	3.182%	01/01/2018-02/28/2018
	PEMS07	883	866	28224	0.452%	05/01/2017-08/31/2017
	PEMS08	170	295	17856	0.696%	07/01/2016-08/31/2016
地铁系统人流量	HZMetro	80	248	/	/	01/01/2019-01/26/2019

3.2 实验设置

在实验中,将所有数据集按照 6:2:2 的比例划分为训练集、验证集和测试集.使用标准化 Min-Max 方法将数据归一化至 $[-1,1]$,将处理后的数据输入 MVSTGCN,其中输入数据为基于历史一小时的交通流量序列,预测未来一个小时的交通流量序列,由于数据集以 5 分钟为时间间隔聚合,因此未来一小时交通流量序列即未来 12 个时间步长交通流量序列.本文基于 PyTorch 框架实现了 MVSTGCN 模型,模型的超参数由验证集的性能决定,模型维度 d 设置为 32,注意力头的数量 h 设置为 8,学习率 lr 设置为 0.001,编码器/解码器层数 L 设置为 5.

3.3 评价指标及基准模型

为了验证本文提出的 MVSTGCN 的有效性,在本节中我们将提出的 MVSTGCN 与以下 11 种交通流量预测方法进行比较,其中前 6 种为基准模型,后 5 种为前沿模型.

(1)HA^[15]:历史均值法,使用相应历史时期的交通流量平均值来预测下一时间片的交通流量值.

(2)VAR^[41]:向量自回归模型,高级时间序列预测模型,能够捕获所有交通序列之间的空间相关性.

(3)SVR^[20]:支持向量回归模型,利用线性支持向量机实现预测任务.

(4)LSTM^[42]:长短时记忆网络,LSTM 作为较为主流的时间序列预测模型,是一种特殊的 RNN 模型,一定程度上解决传统 RNN 所存在的梯度爆炸和梯度消失等问题.

(5)DCRNN^[29]:扩散卷积循环神经网络,使用图上的双向随机游走来捕获空间相关性,并使用具有预定采样的编码器-解码器架构来捕获时间相关性,实现多步交通预测.

(6)STGCN^[13]:时空图卷积网络,通过集合图卷积和门控时间卷积的时空模块,有效捕获全面的时空相关性,进行时空交通流量预测.

(7)Graph WaveNet^[33]:将自适应邻接矩阵引入图卷积网络捕获动态的空间依赖性,并使用扩展随机卷积捕获时间依赖性.

(8)ASTGCN^[30]:基于注意力的时空图卷积网络,分别使用空间注意和时间注意机制,建模空间和时间动态,在真实公路交通流量数据集上取得较好的效果.

(9)STSGCN^[43]:时空同步图卷积网络,构建多个局部时空子图模块以同步捕获局部时空依赖性.

(10)ASTGNN^[32]:基于注意力的时空图神经网络,在时间和空间维度上分别使用时间趋势自注意机制和动态图卷积实现交通数据动态性建模,同时考虑了交通数据的周期性和空间异质性.

(11)STFGNN^[14]:时空融合图神经网络,使用 DTW 算法来构建图,通过对生成的时空图执行融合操作来有效学习隐藏的相关性.

为验证提出 MVSTGCN 的有效性,本文采用平均绝对误差(Mean Absolute Error, MAE),均方根误差(Root Mean Square Error, RMSE)和平均绝对百分比误差(Mean Absolute Percentage Error, MAPE)作为评价指标,具体的计算公式如下:

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|, \quad (22)$$

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}, \quad (23)$$

$$MAPE = \frac{1}{N} \sum_{i=1}^N \frac{|y_i - \hat{y}_i|}{y_i}, \quad (24)$$

其中 N 为样本数据的数量, y_i 为真实值, \hat{y}_i 为预测值.

3.4 实验结果与分析

(1)高速公路流量数据集预测结果分析

将本文提出的 MVSTGCN 模型在四个真实的高速公路数据集进行验证,表 3 显示了本文模型与基线方法在 PEMS 数据集上接下来一个小时(12 步预测)的平均预测结果(表中用粗体表示最优的结果,下划线表示次优

的结果),图 10 显示了不同方法在四个高速公路交通数据上的性能随预测时间间隔增加的变化.结果显示本文方法实验结果均优于所有的基线方法.其中 MVSTGCN 在 PEMS07 和 PEMS08 数据集上的预测性能有较明显的提升,在 PEMS07 中,MVSTGCN 在 MAE、RMSE 和 MAPE 三个指标下与最优方法相比,分别有 10.1%,4.8% 和 11.7%的预测性能提升.在 PEMS08 数据集上,MVSTGCN 在三个指标上的性能提升分别为 14.8%,8.5%和 8.0%.

表 3 各种模型在四个交通流量数据集上的预测结果

数据集	评价指标	HA	VAR	SVR	LSTM	DCRNN	STGCN	Graph WaveNet	ASTGCN	STSGCN	ASTGNN	STFGCN	MVSTGCN
PEMS03	MAE	31.58	23.65	21.97	20.62	18.39	17.55	14.79	17.34	17.48	<u>14.78</u>	16.77	14.63
	RMSE	52.39	38.26	35.29	33.54	30.56	30.42	25.51	29.56	29.21	<u>25.00</u>	28.34	24.98
	MAPE(%)	33.78	24.51	21.51	28.94	20.22	17.34	<u>14.32</u>	17.21	16.78	14.79	16.30	13.59
PEMS04	MAE	38.03	24.54	28.70	26.81	23.65	21.16	19.36	22.93	21.19	<u>18.60</u>	19.83	18.57
	RMSE	59.24	38.61	44.56	40.74	37.12	34.89	31.37	35.22	33.65	<u>30.91</u>	31.88	30.77
	MAPE(%)	27.88	17.24	19.20	22.33	16.05	13.83	13.31	16.56	13.90	<u>12.36</u>	13.02	12.32
PEMS07	MAE	45.12	50.22	32.49	29.71	23.60	25.33	21.22	24.01	24.26	<u>20.62</u>	22.07	18.54
	RMSE	65.64	75.63	50.22	45.32	36.51	39.34	34.12	37.87	39.03	<u>34.00</u>	35.80	32.36
	MAPE(%)	24.51	32.22	14.26	14.14	10.28	11.21	9.07	10.73	10.21	<u>8.86</u>	9.21	7.82
PEMS08	MAE	34.86	19.19	23.25	22.19	18.22	17.50	15.07	18.25	17.13	<u>15.00</u>	16.64	12.78
	RMSE	59.24	29.81	36.16	33.59	28.29	27.09	<u>23.85</u>	28.06	26.80	24.70	26.22	22.61
	MAPE(%)	27.88	13.10	14.64	18.74	11.56	11.29	9.51	11.64	10.96	<u>9.50</u>	10.60	8.74

表 3 的结果表明,统计方法(HA)、传统机器学习方法(SVR)和非图结构深度学习方法(LSTM)的预测性能较差,其原因可能为这些模型只考虑了交通数据中的时间相关性,忽略了其复杂的空间相关性,然而实际交通预测中空间相关性是极其重要的.VAR 虽然能够捕获多个交通序列之间的时间相关性和空间相关性,但其建模非线性和动态时空相关性的能力较弱,预测波动较大.以 DCRNN 和 STGCN 为代表的时空图卷积模型,同时考虑了时间相关性和空间相关性,提升了交通流量预测的性能.然而,DCRNN 作为典型的基于 RNN 时空图交通预测方法,其长期时间依赖性建模能力的限制,预测精度远低于本文模型.STGCN 采用 1D CNN 沿时间维度捕获时间相关性,会受卷积核大小的限制,难以处理长期的时间信息.STSGCN 构建了多个局部时空子图模块以同步捕获局部时空依赖性,但仅使用了简单的滑动窗口来捕获时间相关性同时忽略了全局信息.Graph WaveNet 将扩散卷积嵌入至 TCN 有效学习到时间依赖性,同时使用自适应邻接矩阵捕获隐藏的空间依赖关系,其性能优于部分对比模型.然而 Graph WaveNet 学习的邻接矩阵是静态的,缺乏对图中时空相关性的表征能力,不足以挖掘复杂交通场景下的时空特征.STFGCN 采用传统的 DTW 算法构建图结构,利用时空融合图来获取隐藏的时空关联,同时使用扩张卷积模块捕获局部和全局关联,但忽略了交通数据的动态特性.ASTGCN 使用注意力机制分别建模交通数据的时间动态特性和空间动态特性.ASTGNN 在 ASTGCN 基础上改进了传统的注意力机制,同时考虑了周期性和空间异质性,因此其性能得到大幅度提升.

图 10 显示了各种模型在不同预测时间步长即增加预测时间间隔时,四个高速公路流量数据集上的性能变化,从图中可以看出,随着预测时间间隔的增加,城市路网面临更加复杂的动态变化,城市交通流量预测难度增加,因此不同方法的性能都有所下降,但本文提出的 MVSTGCN 在 MAE、RMSE 和 MAPE 上下降幅度最小,且在不同预测时间步长上均保持了最佳性能.这是由于 MVSTGCN 使用编码器解码器结构,同时设计了路网的全局时空特征学习模块,利用全局特征提取路网全局空间相关性,获得长期时空依赖关系,因此 MVSTGCN 在长期流量预测任务中性能更佳,优势更加明显.

引入了 GCN 和时间分量的流量预测模型,其预测性能与采用经典时间序列预测的模型相比有较大的提升,验证了 GCN 在捕获空间依赖关系上的有效性以及同时捕获时空依赖的必要性.此外,以数据为驱动来构建图结构的预测模型,其性能相较于使用静态图结构的方法有了较大提升,这是由于在多数情况下,预定义的图结构并不是最优的且无法提取复杂的时空相关性特征,而基于数据驱动构建的图结构可以在不需要任何先验知识的指导下提取隐藏的空间依赖.说明挖掘动态的空间依赖关系对提升交通流量预测的性能具有重要的作用.使用

注意力机制建模交通数据时空动态特性的方法也取得了良好的性能,注意力机制捕获交通数据中的动态参数仅依赖于输入数据,且能够关注所有时间片上的全部信息,使得模型更好地捕获长期时间依赖性.

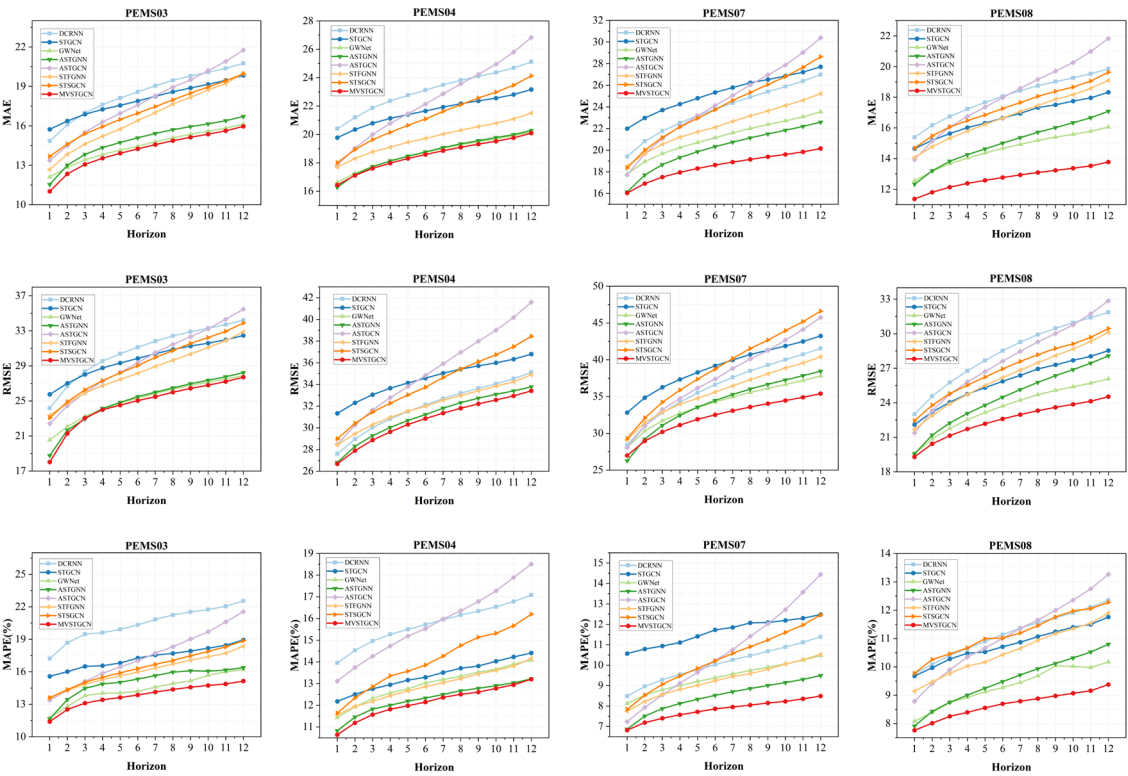


图 10 各种模型在四个高速公路流量数据集上对不同时间步长的预测性能比较

(2)城市地铁人群流量数据集预测结果分析

表 4 显示了本文模型与基线方法在杭州城市内地铁网络上的人群流量数据集上接下来一个小时(12 步预测)的平均预测结果(表中用粗体表示最优的结果,下划线表示次优的结果).

表 4 各种模型在杭州地铁人群流量数据集上的预测结果

数据类型	流入人群流量			流出人群流量		
评价指标	MAE	RMSE	MAPE(%)	MAE	RMSE	MAPE(%)
HA	28.49	49.78	65.73	30.29	55.89	108.78
VAR	17.65	28.10	58.07	22.35	37.96	96.68
SVR	21.94	40.73	49.40	25.59	50.07	91.71
LSTM	22.53	39.33	60.12	26.18	48.91	103.06
DCRNN	12.25	20.91	25.53	18.02	31.45	66.98
STGCN	12.88	22.86	29.66	19.12	33.12	73.66
Graph WaveNet	<u>11.20</u>	<u>19.73</u>	<u>23.75</u>	<u>17.50</u>	<u>30.65</u>	73.65
ASTGCN	13.10	23.23	33.29	19.35	33.20	88.75
STSGCN	12.85	23.20	28.02	18.74	33.12	76.85
ASTGNN	11.46	20.84	24.42	17.94	31.91	72.46
STFGCN	12.54	20.63	24.74	18.13	31.63	73.27
MVSTGCN	10.65	18.43	22.79	17.03	30.21	<u>70.48</u>

从表 4 可以看出,MVSTGCN 在城市地铁人群流量数据集上依然保持了优秀的预测性能,在流入人群流量的预测任务下,MAE、RMSE 和 MAPE 指标下与最优方法相比,分别有 4.9%、6.6%和 4.0%的预测性能提升,在

流出人群流量的预测任务下,MAE 和 RMSE 指标下与最优方法相比,分别有 2.7%和 1.4%的预测性能提升.流出人群流量预测任务的 MAPE 指标相较于 DCRNN 性能略差,这是由于 MVSTGCN 从多视角出发,挖掘路网节点之间多元的空间关联,学习路网的全局特征,而地铁人群流量数据集相较于高速公路流量数据集多元空间关联性较弱,因此性能有所下降,但依旧展现了其优越的预测能力.

实验结果表明,MVSTGCN 在高速公路流量数据集和地铁人群流量数据集上都保持了优越的性能,验证了 MVSTGCN 的有效性 with 优越性.MVSTGCN 分别设计基于多视角动态图卷积模块,发现道路网络中隐藏的动态关联,以捕获潜层的空间相关性,显著提高捕捉局部变化和全局依赖性的能力.同时 MVSTGCN 中的基于局部卷积多头自注意力的时序预测模块可以在时间维度上灵活地建模交通数据的时序变化特性,准确的预测未来时间内的交通流量趋势.

3.5 消融实验

为了进一步评估本文模型中各组件的有效性,我们在 PEMS04 和 PEMS08 数据集上进行了消融实验并分析了实验效果,设计了以下模型变体:

w/o Emb:去除了空间位置和时间位置嵌入的 MVSTGCN,探究嵌入模块对建模的影响.

w/o DGra:去除了动态关联图构建模块的 MVSTGCN,只使用距离图单一视角建模空间相关性,探究构建交通相似图捕捉节点之间相似的功能特性以及动态交通模式影响的重要性.

w/o TrAtt:去除了局部卷积注意力机制的 MVSTGCN,使用传统多头自注意力机制替换时间局部卷积多头自注意力,探究捕捉局部趋势对于交通预测的作用.

w/o DGCN:去除了动态图卷积模块的 MVSTGCN,使用传统图卷积模块替换动态图卷积模块,探究动态图卷积模块动态调整空间相关性强度的有效性.

w/o Glo:去除了全局表示模块的 MVSTGCN,探究捕获全局空间相关性对于模型性能的影响.

w/o RCLN:去除了残差连接和层归一化的 MVSTGCN,研究残差连接和层归一化是否能够提升模型性能.

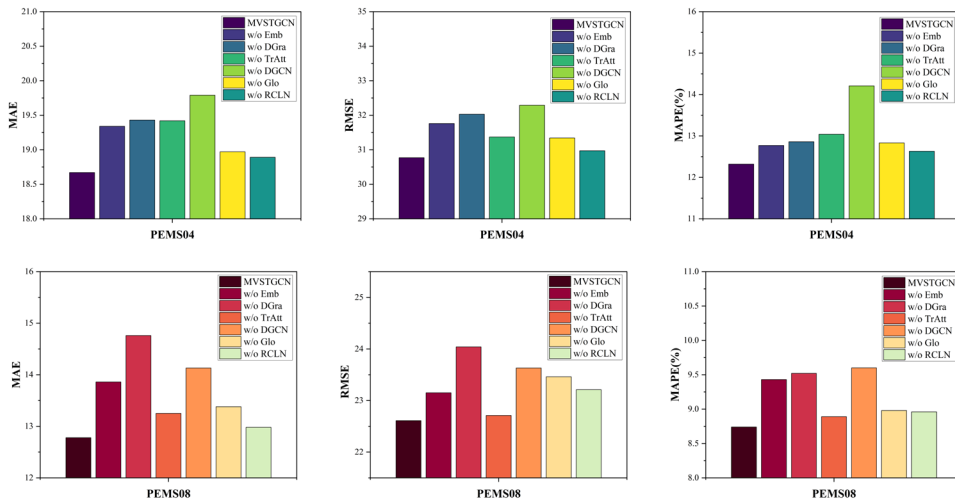


图 11 MVSTGCN 消融实验结果

消融实验的结果如图 10 所示,所有变体的具体设置除上述差异外均与 MVSTGCN 设置保持一致,图中给出了模型在未来一小时的平均预测结果,这些变体在 PEMS04 和 PEMS08 上的实验结果基本相似.可以看出, MVSTGCN 的性能优于其他变体模型,证实了本文模型中每个组件的有效性.

动态关联图构建模块对于整体模型的性能提升至关重要,去除动态关联图构建模块的模型无法捕捉节点之间相似的功能特性与动态交通模式的影响,单一视角建模空间相关性,导致性能显著降低.同时使用传统图卷

积模块替换动态图卷积模块也会导致模型性能降低,这是由于动态图卷积模块可以动态调整空间相关性强度,有效捕捉交通路网中的空间动态特性,w/o DGCN 的性能下降表明了动态图卷积模块的必要性。

去除局部卷积注意力机制的 MVSTGCN 模型性能下降,表明在时间序列建模中学习序列局部上下文信息的重要性,使用局部卷积注意力机制比传统的多头自注意力机制具有更好的预测性能.MVSTGCN 性能优于 w/o Glo,证明了全局空间相关性对预测性能的显著影响,忽略全局空间相关性只关注节点局部之间的依赖关系,会导致预测性能的下降。

去除空间位置和时间位置嵌入的 w/o Emb 相较于 MVSTGCN 性能显著降低,表明使用空间位置嵌入考虑静态空间特征和利用时间位置嵌入捕捉时间序列顺序信息对于模型的重要性,嵌入模块有效捕获了交通数据的空间异质性和时间序列的相关性。

当模型缺少残差连接和层归一化时,模型性能有所下降,表明配备残差连接和层归一化的模型可以解决深层网络训练过程中梯度消失和梯度爆炸问题,帮助模型更好地捕捉交通数据中的序列特征,从而提升模型的精度和稳定性.同时残差连接和层归一化可以帮助模型加速网络的收敛速度,提高模型的泛化性能,更好地处理输入数据的噪声和异常值,从而提升模型的鲁棒性和准确性。

3.6 网络超参数设置的影响

为了进一步研究网络超参数设置的影响,我们设置了不同的网络核心超参数,在 PEMS08 数据集上进行了实验.选择的超参数如下:模型维度 d 、编码器/解码器层的数量 L 、注意力头的数量 h 、两种图表示的融合比例 τ 、全局表示的融合比例 α ,具体的实验结果如图 11 所示。

(1)模型维度 d :在模型训练过程中,模型维度会对模型的性能和效果产生较大的影响,一般来说,模型维度越大,模型对于数据的特征表达能力越强,可以更好地提取序列复杂的特征信息,但模型维度过大会导致训练过拟合,模型泛化能力下降.同时若模型维度过小,则模型无法捕捉足够的特征信息导致欠拟合.为了寻找最佳模型维度,本文将模型维度设置为[16,32,64,128]。

(2)编码器/解码器层的数量 L :编码器/解码器层数量的选择对于模型训练效果同样重要,一般来说,更深的编码器/解码器层可以学习更多的抽象特征,提高模型的表达能力,但过高的层数可能会导致模型过拟合,影响模型性能.因此本文将编码器/解码器层数设置为[2,3,4,5,6],以探究最优编码器/解码器层数。

(3)注意力头的数量 h :注意力头数量作为模型中的重要参数,直接决定了每个输入位置能够关注到输入序列中的信息数量,一般来说,增加注意力头的数量可以提升模型的表达能力和表示能力,但是也会增加模型的计算复杂度和训练难度.本文将注意力头的数量设置为[1,2,4,8,16],以确定最佳的注意力头数量。

(4)两种图表示的融合比例 τ :空间结构图基于静态的空间结构构建,代表了空间结构的邻近性和连通性,动态关联图基于动态的时序相似性构建,能够表征节点间相似的城市功能特性以及交通模式的动态影响.为了探究空间结构图和动态关联图两种视图在提取不同区域之间的双视角时空关联时,两种图表示不同的融合比例对模型预测性能的影响,将两种图表示的融合比例 τ 取值设置为[0.2,0.3,0.4,0.5,0.6,0.7,0.8],探究最佳两种图表示融合比例。

(5)全局表示的融合比例 α :为了探究全局空间适应性和局部动力学之间的相互作用,将全局表示的融合比例 α 取值设置为[0.2,0.3,0.4,0.5,0.6,0.7,0.8],以确定全局表示的最佳融合比例。

从图中可以看出,当模型维度为 32 时,模型取得了最优预测效果.当模型维数为 16 时,模型维数过小,无法捕捉足够的交通序列的特征信息,导致模型效果较差.一定程度上增加模型维数可以增强模型对于交通序列特征的表达能力,提升模型性能,但过高的模型维数会导致过拟合从而影响模型性能。

当编码器/解码器层数量为 5 时,模型性能最优,从图中可以看出,适当增加编码器/解码器层数模型性能有所提升,但当编码器/解码器层数增加为 6 时,模型性能下降.这是由于适当增加编码器/解码器层数可以增强模型对交通数据的抽象提取能力,提高模型的表达能力,同时提高模型的感知范围,更好地捕捉交通数据输入输出之间的长期依赖关系,但过深的编码器/解码器层数可能会导致梯度爆炸或消失,影响模型最终训练效果。

逐渐增加注意力头数量可以提升模型性能,当注意力头数量为 16 时模型取得最优性能.这是由于增加注意

力头的数量可以增强模型学习输入交通序列中局部和全局依赖关系的能力,从而提升模型的性能.同时提高模型学习不同层次的特征表示的能力,有效捕捉交通数据中的复杂模式和动态关系,实现精准的交通长期预测.但增加注意力数量也会增加模型的计算复杂度和参数量,导致训练和推理时间增加,从图中可以看出增加的性能提升出现递减趋势,因此为了在有限的计算资源下实现更好的模型性能,本文在实际对比实验中选择注意力头的数量为 8.

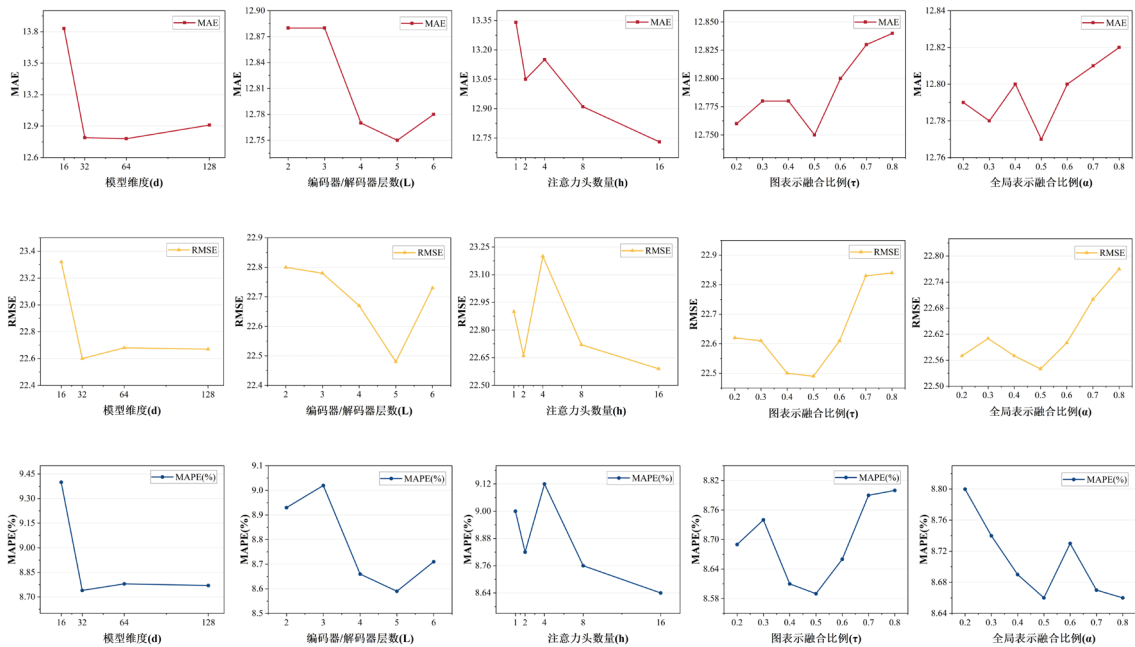


图 12 MVSTGCN 超参数实验结果

当两种图表示融合比例取值为 0.5 时,模型的预测效果最佳,过低或过高的图表示融合比例均会影响模型的预测效果.这是由于静态的空间结构可以捕捉道路网络的拓扑信息,动态的时序关联能够捕获交通流量的动态变化,过高或过低的图表示融合比例会导致模型过于依赖静态或动态信息,导致模型泛化能力下降,降低模型预测性能.同时当两种图融合比例为 0.5 时,能够更好地平衡模型的参数量和复杂度,提高模型的训练效率和稳定性.

当全局表示融合比例取值为 0.5 时,模型的预测效果最佳,过高或过低的全局表示融合比例同样会降低模型预测性能.这是由于当全局相关性权重较大时,模型更加注重整个路网的拓扑结构和交通流量的传播规律,当局部相关性权重较大时,模型更加注重局部区域的空间结构和动态变化,因此当全局表示融合比例为 0.5 时,能够更好地捕捉路网中局部结构和全局相关性之间的依赖关系,充分利用两种信息的优势,从而提升模型预测的准确度.在实际应用中,最优的融合比例可能会受到数据集的不同而有所差异,因此需通过相应的实验和调参以确定最优的全局表示融合比例.

3.7 效率实验

为了更加直观和有效的展现本文模型效果,验证方法的绿色低碳成果,我们比较了本文方法和深度学习方法在四个真实高速公路数据集中每个迭代(epoch)所需的平均训练时间和推理时间.所有实验均在配备 NVIDIA RTX 4090 显卡,13th Gen Intel(R) Core(TM) i9-13900K CPU,128G RAM 运行内存的计算服务器上训练,表 5 显示了效率实验的结果.

表 5 效率实验

数据集	PEMS03		PEMS04		PEMS07		PEMS08	
方法	训练时间 (s/epoch)	推理时间 (s)	训练时间 (s/epoch)	推理时间 (s)	训练时间 (s/epoch)	推理时间 (s)	训练时间 (s/epoch)	推理时间 (s)
DCRNN	59.70	12.61	32.88	6.78	261.18	57.65	18.94	3.42
STGCN	27.28	6.41	15.27	3.65	79.72	18.84	8.16	1.98
Graph WaveNet	22.11	3.00	12.55	1.73	75.60	10.93	13.35	0.96
STSGCN	33.35	1.56	18.19	0.83	107.00	5.43	11.78	0.46
ASTGCN	75.80	9.22	47.87	8.48	197.53	45.39	25.08	5.21
ASTGNN	89.66	32.42	80.34	28.66	289.62	128.29	28.65	12.27
STFGCN	69.44	9.17	40.38	6.27	238.48	89.39	26.79	5.63
MVSTGCN	65.25	8.37	38.27	5.79	169.49	39.78	20.31	4.74

表 5 结果表明 MVSTGCN 在训练和推理阶段都实现了良好的计算效率,早期的图神经网络交通流量预测方法相较于近期提出的图神经网络交通流量预测方法具有更简单的框架和更少的参数,因此早期模型的运行时间较短,但性能较差.DCRNN 使用基于 RNN 的编码器解码器结构,因此运行时间相对较长.Graph WaveNet 在训练和推理阶段都保持着最佳计算效率,这是由于 Graph WaveNet 将扩张因果卷积与图卷积融合,一次生成预测结果,然而 Graph WaveNet 未考虑路网节点之间的多元空间关联,以及节点中局部空间结构和全局空间相关性之间的依赖关系,因此不足以挖掘复杂交通场景下的时空特征.相对来说,STGCN 在推理阶段较慢,因为其迭代地生成多步预测,STSGCN 的参数数量较多,计算效率较低.MVSTGCN 在近期提出的图神经网络交通流量预测方法中训练时间和推理时间上都保持了最短时间,ASTGCN 设置了三个独立分量,分别模拟交通流量的近期依赖性、日周期性和周周期性,因此计算效率较低,同样的,ASTGNN 对周期性进行建模,增加了运行时间.STFGNN 需要生成时空融合图,因此运行速度较慢,而 MVSTGCN 使用了预先生成的多视角时空图,在保持了优秀的预测性能同时有效提高了模型计算效率,实现了机器学习绿色低碳的发展需求.

3.8 预测结果可视化

为了在实际应用中更好地评估模型的性能,将四个高速公路数据集上的节点预测交通流量效果进行可视化展示,图 12 分别展示了四个数据集中节点样本在一天内的交通流量数据.

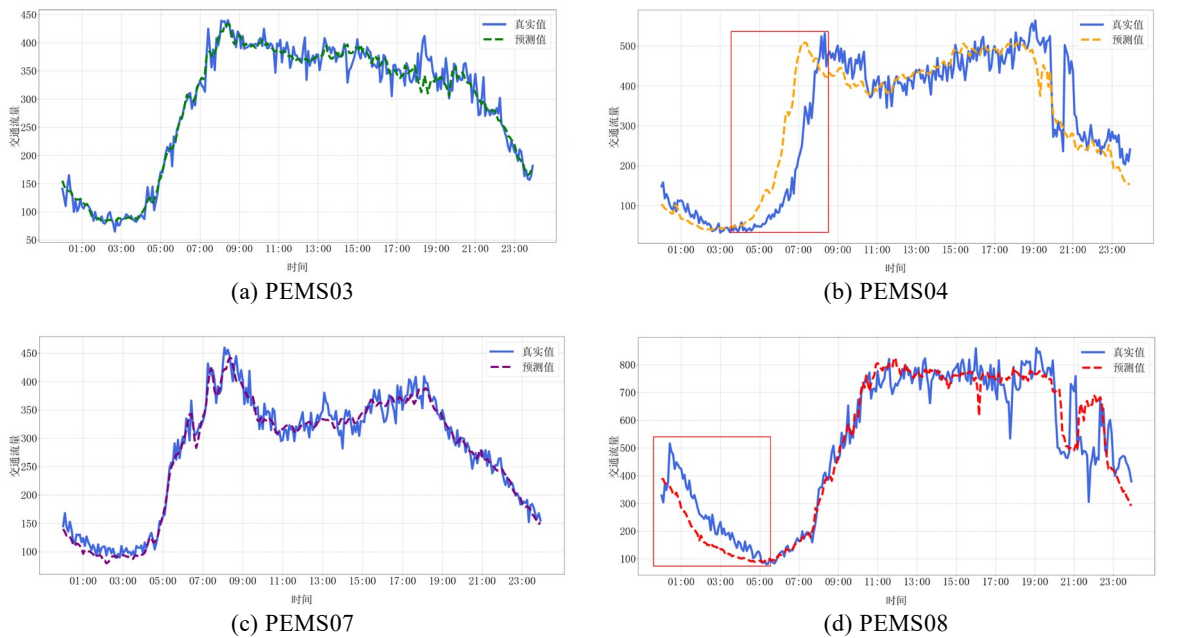


图 13 预测结果可视化

从图 12 中可以看出,MVSTGCN 模型在实际应用中能够较为准确的预测未来交通发展趋势,其中模型在数据集 PEMS03 和 PEMS07 都表现出了良好的预测性能,在数据集 PEMS04 和 PEMS08 的红色方框区域中出现了一定的预测误差,这是由于数据集 PEMS04 和 PEMS08 作为相对简单的数据集,具有较少的节点数量和更少的流量数据,模型在小数据集上的拟合能力较弱,使得预测结果出现很小的偏差.然而,MVSTGCN 模型在 PEMS03 和 PEMS07 的良好表现,证明了本文模型更善于处理复杂多变的交通数据,验证了从多视角出发,挖掘路网节点之间多元的空间关联,学习路网的全局特征,能够实现复杂条件下的城市交通流量预测.

4 总结与未来工作

为了解决现有城市交通流量预测模型中存在的两个问题:1)无法捕捉路网节点之间的时序相似性;2)无法发现路网中局部结构和全局相关性之间的依赖关系,本文提出了一种多视角融合的时空动态图卷积网络模型 MVSTGCN,实现多视角下精准的城市交通流量预测.MVSTGCN 首先从静态路网和动态模式两个视角分别构建空间距离图和动态相似图,不依赖于预定义的静态邻接矩阵,有效地挖掘交通路网的静态信息和动态模式,并捕捉到了节点之间的时序相似性关联.与此同时,MVSTGCN 设计了动态图卷积网络用于发掘节点空间隐藏的动态空间关联.然后,为了捕获时间序列中的局部变化趋势信息和因果关系,MVSTGCN 提出了局部卷积自注意力机制,在捕捉时序变化的过程中还考虑了空间异质性和交通序列顺序信息.最后,MVSTGCN 设计了路网全局流量特征计算模块,有效地挖掘了路网中局部结构和全局相关性之间的依赖关系,提升了路网节点特征的表现力.在四个真实交通网络数据集上的大量实验表明,MVSTGCN 模型优于现有方法.在未来工作中,进一步探索将空间维度和时间维度进行联合建模,设计统一模块捕获时间和空间的交互动态关联,同时考虑交通数据的周期性,降低模型复杂结构,提升模型推理速度.

References:

- [1] Haydari A, Yilmaz Y. Deep reinforcement learning for intelligent transportation systems: A survey. *IEEE Trans. on Intelligent Transportation Systems*, 2020,23(1):11-32.
- [2] Meena G, Sharma D, Mahrishi M. Traffic prediction for intelligent transportation system using machine learning. In: *Proc. of the 3rd International Conference on Emerging Technologies in Computer Engineering: Machine Learning and Internet of Things*. 2020. 145-148.
- [3] Li C, Xu P. Application on traffic flow prediction of machine learning in intelligent transportation. *Neural Computing and Applications*, 2021,33:613-624.
- [4] Reza S, Ferreira MC, Machado J, Tavares JMR. A multi-head attention-based transformer model for traffic flow forecasting with a comparative analysis to recurrent neural networks. *Expert Systems with Applications*, 2022,202:117275.
- [5] Liu Y, Wu C, Wen J, Xiao X, Chen Z. A grey convolutional neural network model for traffic flow prediction under traffic accidents. *Neurocomputing*, 2022,500:761-775.
- [6] Li H, Li X, Su L, Jin D, Huang J, Huang D. Deep spatio-temporal adaptive 3d convolutional neural networks for traffic flow prediction. *ACM Trans. on Intelligent Systems and Technology*, 2022,13(2):1-21.
- [7] Qu Z, Li H, Li Z, Zhong T. Short-term traffic flow forecasting method with MB-LSTM hybrid network. *IEEE Trans. on Intelligent Transportation Systems*, 2020,23(1):225-235.
- [8] Mo J, Gong Z, Chen J. Attentive differential convolutional neural networks for crowd flow prediction. *Knowledge-Based Systems*, 2022,258:110006.
- [9] Feng N, Guo S, Song C, Zhu Q, Wan H. Multi-component Spatial-temporal Graph Convolution Networks for Traffic Flow Forecasting. *Journal of Software*, 2019,30(3):759-769 (in Chinese).
- [10] Lan S, Ma Y, Huang W, Wang W, Yang H, Li P. Dstagnn: Dynamic spatial-temporal aware graph neural network for traffic flow forecasting. In: *Proc. of the 39th International Conference on Machine Learning*. 2022. 162:11906-11917.
- [11] Choi J, Choi H, Hwang J, Park N. Graph neural controlled differential equations for traffic forecasting. In: *Proc. of the 36th AAAI Conference on Artificial Intelligence*. 2022. 6367-6374.

- [12] Zhao L, Song Y, Zhang C, Liu Y, Wang P, Lin T, Deng M, Li H. T-gcn: A temporal graph convolutional network for traffic prediction. *IEEE Trans. on Intelligent Transportation Systems*, 2019,21(9):3848-3858.
- [13] Yu B, Yin H, Zhu Z. Spatio-temporal graph convolutional networks: A deep learning framework for traffic forecasting. *arXiv preprint arXiv:1709.04875*, 2017.
- [14] Li M, Zhu Z. Spatial-temporal fusion graph neural networks for traffic flow forecasting. In: *Proc. of the 36th AAAI Conference on Artificial Intelligence*. 2021. 4189-4196.
- [15] Li Y, Shahabi C. A brief overview of machine learning methods for short-term traffic forecasting and future directions. *Sigspatial Special*, 2018,10(1):3-9.
- [16] Tedjopurnomo DA, Bao Z, Zheng B, Choudhury FM, Qin AK. A survey on modern deep neural network for traffic prediction: Trends, methods and challenges. *IEEE Trans. on Knowledge and Data Engineering*, 2020,34(4):1544-1561.
- [17] Chen F, Chen Z, Biswas S, Lei S, Ramakrishnan N, Lu CT. Graph convolutional networks with kalman filtering for traffic prediction. In: *Proc. of the 28th International Conference on Advances in Geographic Information Systems*, 2020:135-138.
- [18] Yin X, Wu G, Wei J, Shen Y, Qi H, Yin B. Deep learning on traffic prediction: Methods, analysis, and future directions. *IEEE Trans. on Intelligent Transportation Systems*, 2021,23(6):4927-4943.
- [19] Lin G, Lin A, Gu D. Using support vector regression and K-nearest neighbors for short-term traffic flow prediction based on maximal information coefficient. *Information Sciences*, 2022,608:517-531.
- [20] Xu H, Jiang C. Deep belief network-based support vector regression method for traffic flow forecasting. *Neural Computing and Applications*, 2020,32:2027-2036.
- [21] Boukerche A, Wang J. Machine learning-based traffic prediction models for intelligent transportation systems. *Computer Networks*, 2020,181:107530.
- [22] Minaee S, Boykov Y, Porikli F, Plaza A, Kehtarnavaz N, Terzopoulos D. Image segmentation using deep learning: A survey. *IEEE Trans. on Pattern Analysis and Machine Intelligence*, 2021,44(7):3523-3542.
- [23] Otter DW, Medina JR, Kalita JK. A survey of the usages of deep learning for natural language processing. *IEEE Trans. on Neural Networks and Learning Systems*, 2020,32(2):604-624.
- [24] Zhang J, Zheng Y, Qi D. Deep spatio-temporal residual networks for citywide crowd flows prediction. In: *Proc. of the 31th AAAI Conference on Artificial Intelligence*, 2017.
- [25] Zheng Z, Yang Y, Liu J, Dai HN, Zhang Y. Deep and embedded learning approach for traffic flow prediction in urban informatics. *IEEE Trans. on Intelligent Transportation Systems*, 2019,20(10):3927-3939.
- [26] Liu X, Zhao Z, Zhang Y, Liu C, Yang F. Social Network Rumor Detection Method Combining Dual-Attention Mechanism with Graph Convolutional Network. *IEEE Trans. on Computational Social Systems*, 2022:1-12.
- [27] Chen L, Tang X, Chen W, Qian Y, Li Y, Zhang Y. A dual graph convolution based temporal knowledge graph representation learning method using historical relation. *ACM Trans. on Knowledge Discovery from Data*, 2021,16(3):1-18.
- [28] Shen Y, Wu Y, Zhang Y, Shan C, Zhang J, Letaief BK, Li D. How powerful is graph convolution for recommendation? In: *Proc. of the 30th ACM International Conference on Information & Knowledge Management*. 2021. 1619-1629.
- [29] Li Y, Yu R, Shahabi C, Liu Y. Diffusion convolutional recurrent neural network: Data-driven traffic forecasting. *arXiv preprint arXiv:1707.01926*, 2017.
- [30] Guo S, Lin Y, Feng N, Song C, Wan H. Attention based spatial-temporal graph convolutional networks for traffic flow forecasting. In: *Proc. of the 33th AAAI Conference on Artificial Intelligence*. 2019. 922-929.
- [31] Zheng C, Fan X, Wang C, Qi J. Gman: A graph multi-attention network for traffic prediction. In: *Proc. of the 33th AAAI Conference on Artificial Intelligence*. 2020. 1234-1241.
- [32] Guo S, Lin Y, Wan H, Li X, Cong G. Learning dynamics and heterogeneity of spatial-temporal graph data for traffic forecasting. *IEEE Trans. on Knowledge and Data Engineering*, 2021,34(11):5415-5428.
- [33] Wu Z, Pan S, Long G, Jiang J, Zhang C. Graph wavenet for deep spatial-temporal graph modeling. *arXiv preprint arXiv:1906.00121*.
- [34] Bai L, Yao L, Li C, Wang X, Wang C. Adaptive graph convolutional recurrent network for traffic forecasting. *Advances in Neural Information Processing Systems*, 2020,33:17804-17815.

- [35] Fang Z, Long Q, Song G, Xie K. Spatial-temporal graph ode networks for traffic flow forecasting. In: Proc. of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining. 2021. 364-373.
- [36] Shuman DI, Narang SK, Frossard P, Ortega A, Vandergheynst P. The emerging field of signal processing on graphs: Extending high-dimensional data analysis to networks and other irregular domains. IEEE Signal Processing Magazine, 2013,30(3):83-98.
- [37] Berndt DJ, Clifford J. Using dynamic time warping to find patterns in time series. In: Proc. of the 3rd International Conference on Knowledge Discovery and Data Mining. 1994. 359-370.
- [38] Salvador S, Chan P. Toward accurate dynamic time warping in linear time and space. Intelligent Data Analysis. 2007,11(5):561-580.
- [39] Vaswani A, Shazeer N, Parmar N, Uszkoreit J, Jones L, Gomez AN, Kaiser Ł, Polosukhin I. Attention is all you need, In: Proc. of the 31st International Conference on Neural Information Processing Systems. 2017. 6000-6010.
- [40] Chen C, Petty K, Skabardonis A, Varaiya P, Jia Z. Freeway performance measurement system: mining loop detector data. Transportation Research Record, 2001,1748(1):96-102.
- [41] Sun T. Research on Urban Traffic Flow Forecasting Based on Vector Autoregression. Beijing: Beijing Jiaotong University, 2022(in Chinese).
- [42] Fang W, Zhuo W, Song Y, Yan J, Zhou T, Qin J. Δfree-LSTM: An error distribution free deep learning for short-term traffic flow forecasting. Neurocomputing, 2023,526:180-190.
- [43] Wang X, Ma Y, Wang Y, Jin W, Wang X, Tang J, Jia C, Yu J. Traffic flow prediction via spatial temporal graph neural network. In: Proc. of the Web Conference 2020. New York: Association for Computing Machinery, 2020. 1082-1092.

附中文参考文献:

- [9] 冯宁, 郭晟楠, 宋超, 朱琪超, 万怀宇. 面向交通流量预测的多组件时空图卷积网络. 软件学报, 2019, 30(03): 759-769.
- [41] 孙天瑞. 基于向量自回归的城市交通流量预测算法研究. 北京: 北京交通大学, 2022.